

Proyecto Final

Modelització Estadística

Jordi Cortés Dante Conti



Diciembre 2025

Grupo:

Alex Latorre, Javier Aranda, Nicolás Rosales, Robert
Ostrozhinskiy

Universitat Politècnica de Catalunya

1. Introducción	4
i. Problema	4
ii. Data	4
a. Fuente	4
b. Cómo conseguimos los datos	4
c. Descripción del dataset	5
d. Estructura del Dataset	7
e. Pre-procesamiento	9
iii. Work Plan	10
a. Equipo e Información del Proyecto	10
b. Assignment Chart	10
c. Gantt Diagram	11
d. Prevención de Riesgos	11
iv. Objetivos	12
2. Análisis Estadístico Inicial	13
i. Pre-procesamiento	13
a. Carga Inicial y Exploración	13
b. Identificación de la Variable Objetivo	13
c. Criterios de Selección de Características	13
c.1 Criterio de Datos Faltantes	13
c.2 Criterio de Correlación con la Variable Objetivo	13
c.3 Excepciones Basadas en Relevancia Teórica	14
d. Resultado de la Selección	14
e. Homogeneización de Valores Faltantes	14
f. Eliminación de Filas Incompletas	15
g. Conversión a Factores	15
h. Eliminación NA's de la Variable Objetivo	15
i. Dataset Final	15
ii. Univariate Descriptive Statistics	16
iii. Bivariate Descriptive Analysis	18
a. Interacciones de las Variables	23
iv. Conclusiones	25
a. Estructura de Variables y Sesgo Univariado	25
b. Relaciones Bivariadas y Detección de Features del modelo binario	27
c. Interacciones de Features	27
d. Final Thoughts	27
3. Generalized Linear Models (GLMz)	28
i. Model fitting	28
a. Modelo 1 (familia gaussiana, link identidad)	28
b. Modelo 2 (familia gaussiana, link log)	28
b. Modelo 3 (familia Gamma, link log)	29
ii. Model Validation (deviance statistic)	29
a. Validación Numérica (Modelo 1)	29

b. Validación Numérica (Modelo 2)	29
c. Validación Numérica (Modelo 3)	30
d. Validación Gráfica (Modelo 1)	30
e. Validación Gráfica (Modelo 2)	30
f. Validación Gráfica (Modelo 3)	31
g. ANOVAS	32
iii. Model Interpretation	33
1. Género (RIAGENDR)	33
2. Edad (RIDAGEYR)	33
3. Etnicidad (RIDRETH3)	34
4. Nivel Educativo (DMDEDUC2)	34
5. Idioma e Intérprete (SIALANG, SIAINTRP)	34
6. Tamaño y Composición del Hogar	35
7. Género y Edad del Cabeza de Hogar	36
8. Educación del Cabeza de Hogar (DMDHREDU)	36
9. Estado Civil del Cabeza de Familia (DMDHRMAR)	37
10. Interacción Educación × Idioma (DMDEDUC2 × SIALANG)	37
11. Ponderación (WTINT2YR)	38
12. Conclusiones Generales	38
iv. Presentación Modelo Binario	38
v. Binary Model fitting	39
a. Modelo 1 (balanced data)	39
b. Modelo 2 (unbalanced data)	39
vi. Binary Model Validation	39
a. AUC - ROC validation	39
b. Validación Gráfica	40
c. Simplificación modelo binario	41
d. Resumen	42
vii. Interpretación Modelo Binario	43
1. Género (RIAGENDR)	43
2. Edad (RIDAGEYR)	43
3. Etnicidad (RIDRETH3)	44
4. Ciudadanía (DMDCITZN)	44
5. Nivel educativo (DMDEDUC2)	44
6. Idioma de la entrevista (SIALANG)	45
7. Conclusión general	45
4. Time Series (TS)	46
i. Selección de Dataset	46
ii. Preguntas a Investigar	48
iii. Modelo Series Temporales	49
a. Transformación Logarítmica	49
b. Diferenciación para Estacionariedad	50
c. Identificación del Modelo	50

d. Diagnóstico del Modelo	51
iv. Resultados y Validación	52
a. Recesión de Reagan (1980-1983)	53
b. Crisis DotCom (2001-2003)	53
c. Gran Recesión (2008-2010)	53
d. COVID-19 (2020-2021)	53
v. Conclusiones	54
5. PCA	56
i. Screeplot: Selección del Número de Componentes Principales	57
a. Interpretación del Screeplot	57
b. Criterio de Selección	58
ii. Factorial Map Visualization: Círculo de Correlaciones	59
a. Interpretación del Mapa Factorial	60
iii. Interpretation: Significado de los Componentes Principales	61
a. Componente Principal 1 (30.6% de varianza)	61
b. Componente Principal 2 (18% de varianza)	61
c. Componente Principal 3 (13.6% de varianza)	61
d. Componente Principal 4 (10.1% de varianza)	62
e. Síntesis General	62
6. Clustering	63
i. Clustering jerárquico sobre los datos originales	63
a. Descripción de los datos usados	63
b. Método de clustering utilizado	64
c. Dendrogramas	65
d. Número de clústeres escogido	66
e. Distribución del tamaño de los clústeres	67
g. Análisis de la estructura de tamaños	68
ii. Partitional Clustering	69
a. Descripción de los datos usados	69
b. Método de clustering usado	70
c. Justificación del número óptimo de clústeres	71
d. Representación Visual	73
e. Tamaños de los clusters	74
f. Distribución de tamaños de los clústeres K-Prototypes	74
g. Análisis de la estructura de tamaños en K-Prototypes	75
h. Comparación entre métodos	75
iii. Profiling of Clusters	76
a. Análisis de Distribuciones Condicionales y Tests Estadísticos	76
b. Características Intrínsecas y Diferenciadores entre Clústeres	76
b.i. Cluster 1: Población General Nativa Angloparlante	76
b.ii. Cluster 2: Inmigrantes Cualificados de Origen Asiático	77
b.iii. Cluster 3: Inmigrantes Hispanos en Situación Socioeconómica Vulnerable	77
iv. Visualización Gráfica de Perfiles: Boxplots y Gráficos de Distribución	78

a. Dimensión Socioeconómica	78
b. Dimensión Cultural y Demográfica	80
c. Estructura Familiar	82
v. Tests Específicos de Perfilado para Variables Clave	83
a. Cluster 2: Confirmación de Estatus Económico Superior	83
b. Cluster 3: Confirmación de Vulnerabilidad Económica	83
vi. Plantillas de Caracterización de Clústeres	84
a. Template 1: "Mainstream Nativo"	84
b. Template 2: "Élite Inmigrante Cualificada (Asiática)"	85
c. Template 3: "Inmigrantes Hispanos Vulnerables"	85
vii. Conclusión General del Profiling	86
7. Discusión y Conclusiones	87
i. Determinantes Individuales de la Vulnerabilidad (GLMz)	87
ii. Estructura Poblacional de la Desigualdad (Clustering y PCA)	87
iii. Vulnerabilidad Histórica ante Crisis (Time Series)	88
iv. Integración y Síntesis	88
8. Comparativa Gantt	89
i. Conclusión de las diferencias entre los diagramas Gantt	90

1. Introducción

i. Problema

Este proyecto busca entender la vulnerabilidad socioeconómica en EEUU a dos niveles:

- MICRO (NHANES): Identificar qué características individuales (salud, educación, demografía) predicen vulnerabilidad económica medida por INDFMPIR (ratio ingreso/pobreza).
- MACRO (CPS ASEC): Cuantificar cómo estas vulnerabilidades se manifiestan durante crisis económicas, identificando qué grupos demográficos experimentan los mayores aumentos en pobreza.

La integración de ambas perspectivas permite:

- 1) Caracterizar factores de riesgo a nivel individual (GLM)
- 2) Observar cómo estos se traducen en impactos por grupo durante recesiones (Time Series)

ii. Data

a. Fuente

El conjunto de datos proviene de la Encuesta Nacional de Examen de Salud y Nutrición (NHANES).

b. Cómo conseguimos los datos

Primero buscamos conjuntos de datos en el sitio web oficial de NHANES del CDC para asegurarnos de que cumplieran con los requisitos del proyecto.

Como los archivos originales estaban en formato XPT y resultaba difícil transformarlos, descargamos una versión desde Kaggle, que ofrece los mismos datos en un formato CSV más accesible.

c. Descripción del dataset

El NHANES (National Health and Nutrition Examination Survey) es un programa continuo del Centro Nacional de Estadísticas de Salud (NCHS), dependiente de los Centros para el Control y la Prevención de Enfermedades (CDC) de Estados Unidos.

Su propósito es evaluar el estado de salud, la dieta y la nutrición de la población civil no institucionalizada de EE.UU., recopilando datos representativos a nivel nacional que combinan entrevistas, cuestionarios, exámenes físicos y pruebas de laboratorio.

El NHANES se compone de varias secciones o módulos de datos, organizadas por temas o tipos de información.

Entre las principales partes se incluyen:

a) Datos demográficos

Incluyen información básica sobre los participantes:

- Edad, sexo, raza/etnicidad
- Nivel educativo y situación económica
- Tamaño del hogar y lugar de residencia

b) Datos dietéticos (Dietary Data)

Evalúan los hábitos alimenticios de los participantes mediante:

- Recordatorios de consumo de alimentos de 24 horas
- Cuestionarios de frecuencia alimentaria
- Análisis de nutrientes y consumo energético

c) Exámenes de salud (Examination Data)

Son mediciones físicas realizadas por personal médico en unidades móviles:

- Peso, altura, índice de masa corporal (IMC)
- Presión arterial, densidad ósea, fuerza muscular
- Exámenes dentales, visuales y auditivos
- Evaluaciones médicas especializadas (por ejemplo, pulmonares o cardiovasculares)

d) Datos de laboratorio (Laboratory Data)

Incluyen resultados de análisis de sangre, orina y otros fluidos corporales:

- Niveles de glucosa, colesterol, hierro, vitaminas y minerales
- Marcadores de enfermedades infecciosas
- Detección de exposición a contaminantes ambientales (como plomo o mercurio)

En nuestro caso, decidimos investigar los datos demográficos. En la siguiente tabla, se puede apreciar que definición tiene cada variable del dataset.

Tabla 01: Descripción de las Variables del Dataset

AIALANGA	Idioma del cuestionario ACASI (MEC)
DMDBORN4	País de nacimiento
DMDCITZN	Ciudadanía estadounidense
DMDEDUC2	Nivel educativo más alto
DMDEDUC3	Nivel educativo más alto
DMDFMSIZ	Tamaño de la familia
DMDHHSIZ	Tamaño del hogar
DMDHHSZA	Niños ≤ 5 en el hogar
DMDHHSZB	Niños 6–17 en el hogar
DMDHHSZE	Adultos ≥ 60 en el hogar
DMDHRAGE	Edad del referente del hogar
DMDHRBR4	País de nacimiento del referente
DMDHREDU	Educación del referente del hogar
DMDHRGND	Sexo del referente del hogar
DMDHRMAR	Estado civil del referente
DMDHSEDU	Educación del cónyuge del referente
DMDMARTL	Estado civil del participante
DMDYRSUS	Años en EE. UU.
DMQADFC	Servicio en misiones/zonas de conflicto
DMQMILIZ	Servicio activo en fuerzas armadas (EE. UU.)
FIAINTRP	Intérprete en entrevista familiar
FIALANG	Idioma de la entrevista familiar
FIAPROXY	Entrevista familiar con proxy
INDFMIN2	Ingreso familiar total (rango)
INDFMPIR	Índice ingreso/pobreza (PIR)
INDHHIN2	Ingreso del hogar total (rango)
MIAINTRP	Intérprete en entrevista CAPI MEC

MIALANG	Idioma de la entrevista CAPI MEC
MIAPROXY	Entrevista CAPI MEC con proxy
RIAGENDR	Sexo del participante
RIDAGEMN	Edad en meses (selección)
RIDAGEYR	Edad en años (selección)
RIDEXAGM	Edad en meses (examen)
RIDEXMON	Periodo semestral del examen
RIDEXPRG	Embarazo (mujeres 20–44) en MEC
RIDRETH1	Raza/origen hispano (recod.)
RIDRETH3	Raza/origen hispano (con asiático no hispano)
RIDSTATR	Estado de entrevista/examen
SDDSRVYR	Ciclo de liberación de datos
SDMVPSU	PSU enmascarada para varianza
SDMVSTRA	Estrato enmascarado para varianza
SEQN	Número de secuencia del encuestado
SIINTRP	Intérprete en entrevista de SP
SIALANG	Idioma de la entrevista de SP
SIAPROXY	Entrevista de SP con proxy
WTINT2YR	Peso de entrevista (2 años)
WTMEC2YR	Peso de examen MEC (2 años)

d. Estructura del Dataset

Tabla 02: Estructura del Dataset

Numero de filas	10175
Numero de variables	47
Variables Numericas	11
Variables Numericas	6
Variables Categoricalas	24
Otros	4

Tabla 03: % de Valores Faltantes del Dataset

Variable	Missings	Missing %
RIDAGEMN	9502	93.39
DMQADFC	9632	94.66
RIDEXAGM	5962	58.59
RIDEXPRG	8866	87.14
DMDYRSUS	8267	81.25
DMDEDUC3	7372	72.45
DMDEDUC2	4406	43.30
DMDMARTL	4406	43.30
DMQMILIZ	3914	38.47
AIALANGA	3858	37.92
MIALANG	2864	28.15
MIAPROXY	2863	28.14
MIAINTRP	2862	28.13
DMDHSEDU	4833	47.50
INDFMPIR	785	7.71
RIDEXMON	362	3.56
DMDHRBR4	297	2.92
DMDHREDU	294	2.89
FIALANG	121	1.19
FIAPROXY	121	1.19
FIAINTRP	121	1.19
INDHHIN2	133	1.31
INDFMIN2	123	1.21
DMDHRMAR	123	1.21
SIAPROXY	1	0.01
DMDCITZN	4	0.04

El porcentaje de datos faltantes en total es de aproximadamente 17.16 %.

e. Pre-procesamiento

Nuestra idea de pre-procesamiento sigue tres filtros:

Filtro 1 - Datos faltantes: Eliminar columnas con >50% de missing values, evaluando caso por caso aquellas entre 40-50% según relevancia teórica. Tras homogeneizar missing values, eliminar filas con valores 0 en variables críticas, asegurando observaciones completas en predictores clave.

Filtro 2 - Correlación con objetivo: Calcular correlación absoluta con INDFMPIR, estableciendo un mínimo. Variables con correlación inferior se descartan.

Filtro 3 - Relevancia conceptual: Mantener variables demográficas fundamentales (edad, género, etnicidad, ciudadanía, educación) incluso con correlaciones moderadas, por su importancia teórica en el estudio de vulnerabilidad socioeconómica.

Dataset Final

El resultado del pre-procesamiento acabará siendo un conjunto de datos optimizado que cumple:

- 20 variables con relevancia correlacional y teórica
- Datos completos en todas las variables de modelado
- Tipificación correcta (factores vs. numéricas)
- Variable objetivo completamente observada
- Tamaño muestral robusto (n=5,121)

Este dataset limpio constituye la base para todo el análisis estadístico a llevar a cabo.

iii. Work Plan

a. Equipo e Información del Proyecto

Miembros:

- Alex (Project Manager)

Responsable de la coordinación general y asegurar que se cumplan los plazos.

- Nicolas

Gestión de datos y el modelado estadístico.

- Robert

Interpretación del análisis y la visualización.

- Javier

redacción del informe y la presentación.

b. Assignment Chart

Tabla 03: Roles de los Miembros del Equipo

Participant	Alex	Nicolas	Robert	Javier
T1	X	X	X	X
T2	X	X	X	
T3	X	X	X	X
T4		X	X	X
T5	X	X		X
T6	X		X	X
T7	X	X	X	
T8		X	X	X
T9	X		X	X
T10	X	X	X	X
T11	X	X		X
T12	X		X	X

Tabla 04: Distribución de Tasks

Task	Task ID
Data Preprocessing	T1
Initial Statistical Analysis	T2
GLM Modeling	T3
Time Series Analysis	T4
D4 Report & Script Compilation	T5
D4 Presentation Preparation	T6
PCA Analysis	T7
Clustering	T8
Profiling of Clusters	T9
Discussion, Conclusions & Plan Review	T10
D5 Report & Script Compilation	T11
D5 Presentation Preparation	T12

c. Gantt Diagram

Figura 01: Diagrama Gantt de organización

	28/09	5/10	12/10	19/10	26/10	2/11	9/11	16/11	23/11	30/11
Tarea 1	Data preprocessing									
Tarea 2		Initial statistical analysis								
Tarea 3			GLM Modeling							
Tarea 4				Time series analysis						
Tarea 5				Report Script and Coordination						
Tarea 6					Presentation Preparation					
Tarea 7						PCA Analysis				
Tarea 8						Clustering				
Tarea 9							Profiling of clusters			
Tarea 10								Discussion, conclusions & Plan Review		
Tarea 11									Report & Script Compilation	
Tarea 12									Presentation Preparation	

d. Prevención de Riesgos

Tabla 05: Riesgos y cómo solventarlos

Riesgo	How to Prevent	How to manage
Falta de datos temporales	Verificar las variables temporales desde el inicio y asegurar que el preprocesamiento cumpla con los supuestos de modelos GLM o de series temporales (TS).	Si el conjunto de datos no contiene información temporal adecuada, buscar un conjunto de datos alternativo que sí la incluya.
Dataset con demasiados missings	Inspeccionar los datos faltantes al comienzo del preprocesamiento: calcular el porcentaje y los patrones de ausencia. Definir una estrategia de imputación antes del modelado. Aplicar métodos de imputación múltiple cuando sea posible. Eliminar variables o filas solo si existe una justificación sólida.	Usar modelos robustos que toleren datos incompletos. Documentar claramente las limitaciones en el informe final.
Rendimiento insuficiente de los modelos	Elegir el enlace (link) y la familia de distribución adecuados según la variable respuesta. Verificar escalado de variables y colinealidad antes del ajuste del modelo.	Probar enlaces o familias alternativas, simplificar el modelo o transformar variables si es necesario. Consultar con el profesor o tutor en caso de persistir los problemas de ajuste.

Indisponibilidad de un miembro del equipo	Asignar al menos dos integrantes por tarea para evitar bloqueos.	Si un miembro no está disponible, reasignar el trabajo pendiente equilibrando los esfuerzos del resto del equipo. El líder del equipo asume las tareas prioritarias para mantener el cronograma y evitar retrasos en el camino crítico.
Dificultades técnicas	Utilizar control de versiones (GitHub) y documentar todas las dependencias y versiones en un archivo requirements.txt.	Crear un entorno virtual limpio y reinstalar las dependencias desde cero. Actualizar o degradar paquetes hasta lograr un entorno estable y funcional.

iv. Objetivos

El objetivo principal es integrar evidencia micro (NHANES) y macro (CPS ASEC) para caracterizar factores asociados a vulnerabilidad y su evolución en el tiempo. Además, tenemos como objetivos adicionales:

- Preprocesar y describir NHANES, justificando decisiones sobre missing, outliers y transformaciones.
- Ajustar y validar dos modelos GLMz (respuesta numérica y binaria) adecuados a la distribución de las variables.
- Construir un modelo ARIMA anual sobre la serie agregada de pobreza (All Races), siguiendo el flujo de clase (transformación logarítmica, $d=1$, identificación AR, validación de residuos, pronóstico).
- Cuantificar, por grupo demográfico, los aumentos de pobreza (pp) en cuatro crisis: Reagan (1980-1983), DotCom (2001-2003), Gran Recesión (2008-2010) y COVID-19 (2020-2021), comparando picos con un baseline de 3 años previos.
- Entregar un informe reproducible con figuras/tablas que respondan: qué grupos fueron más golpeados en cada recesión y con qué magnitud.

2. Análisis Estadístico Inicial

i. Pre-procesamiento

a. Carga Inicial y Exploración

El dataset original contiene 47 columnas con información diversa sobre características individuales, familiares y socioeconómicas de los participantes. La exploración inicial reveló una estructura compleja con múltiples tipos de datos, valores faltantes codificados de diferentes formas, y un número de variables demasiado grande para un modelado eficiente.

b. Identificación de la Variable Objetivo

Para guiar el proceso de selección de características, identificamos INDFMPIR (ratio de ingresos respecto al umbral de pobreza) como la variable objetivo principal del análisis de regresión continua. Esta variable representa una medida de estatus socioeconómico y permite evaluar cómo las características demográficas, educativas y familiares se relacionan con la situación económica de los individuos. Como el número de columnas es elevado, decidimos primero escoger la variable que usaremos para el modelo de regresión, para de esta manera poder añadir criterios de eliminación de columnas dependiendo de la correlación con esta variable objetivo.

c. Criterios de Selección de Características

Dada la alta dimensionalidad del dataset original (47 columnas), necesitábamos reducir el número de variables de manera sistemática. Aplicamos los siguientes criterios:

c.1 Criterio de Datos Faltantes

Eliminamos todas las columnas con más del 50% de valores faltantes, ya que estas variables no proporcionaban suficiente información para un análisis robusto. Además, evaluamos con cuidado las columnas con entre 40% y 50% de datos faltantes, descartándolas en la mayoría de los casos salvo cuando mostraban relevancia teórica o relación clara con la variable objetivo.

c.2 Criterio de Correlación con la Variable Objetivo

Para las columnas que pasaban el filtro de datos faltantes, calculamos la correlación absoluta (Eta para variables categóricas, Pearson para continuas) con INDFMPIR. Establecimos un umbral mínimo de correlación absoluta de 0.15 para considerar que una variable tiene relevancia predictiva suficiente. Las variables con correlaciones menores a este umbral fueron descartadas por considerarse de débil asociación con el resultado de interés. También eliminamos columnas con información redundante como por ejemplo variables como WTMEC2YR, que nos proporcionan información similar a WTINT2YR. Hemos intentado mantener al menos una columna de cada que proporcione información única e independiente para evitar colinealidad entre variables a no ser que la información no fuera relevante.

c.3 Excepciones Basadas en Relevancia Teórica

A pesar de los criterios anteriores, mantuvimos algunas variables con correlaciones moderadas o datos faltantes intermedios cuando su relevancia era clara. Por ejemplo, DMQMILIZ (participación en servicio militar) fue retenida tanto para el análisis de regresión como para desarrollar un modelo binario independiente, aunque su correlación con INDFMPIR fuera moderada, debido a su importancia sociológica, lo mismo con variables como por ejemplo el lugar de nacimiento, la edad, el género, etc.

d. Resultado de la Selección

Del total de 47 columnas originales, seleccionamos 20 variables para el análisis posterior:

- Variables demográficas: RIAGENDR (género), RIDAGEYR (edad del participante), RIDRETH3 (etnicidad)
- Variables de lugar de nacimiento y ciudadanía: DMDBORN4, DMDCITZN
- Variables educativas: DMDDEDUC2 (educación del participante), DMDHREDU (educación del cabeza de hogar)
- Variables lingüísticas: SIALANG (idioma de entrevista), SIAINTRP (uso de intérprete)
- Variables de estructura y composición del hogar: DMDFMSIZ (tamaño de familia), DMDHHSZA (niños <5 años), DMDHHSZB (niños 6-17 años), DMDHHSZE (adultos ≥60 años), DMDHRGND (género del cabeza), DMDHRAGE (edad del cabeza), DMDHRBR4 (número de hermanos del cabeza), DMDHRMAR (estado civil del cabeza)
- Variables de ponderación: WTINT2YR (pesos de la encuesta)
- Variable binaria de interés: DMQMILIZ (participación en servicio militar)
- Variable objetivo: **INDFMPIR**

e. Homogeneización de Valores Faltantes

Una vez seleccionadas las columnas relevantes, nos encontramos con un problema común en encuestas: los valores faltantes estaban codificados de múltiples formas. Específicamente:

- Los valores 7 o 77 representaban "negación a responder" (refused)
- Los valores 9 o 99 representaban "no sabe" (don't know)
- Los valores NA representaban datos ausentes en el formato de R

Para simplificar la representación y mantener consistencia en el tratamiento de valores faltantes, se agruparon todas estas categorías bajo un único código: **0**. Esta codificación permitiría identificar fácilmente las filas con datos faltantes en variables críticas.

f. Eliminación de Filas Incompletas

Tras homogeneizar de códigos de valores faltantes (ahora representados como 0), eliminamos todas las filas que contenían al menos un valor 0 en las columnas críticas: DMDBORN4, DMDCITZN, DMDEDUC2, DMDHRBR4, DMDHREDU, DMQMILIZ y DMDHRMAR.

Esta estrategia asegura que el análisis subsecuente se realiza sobre un dataset con observaciones completas en las variables más importantes para el modelado. Aunque este proceso resulta en una reducción del tamaño muestral, garantiza la calidad e integridad de los datos para fases posteriores.

g. Conversión a Factores

Una vez completado el proceso de limpieza, identificamos todas las variables categóricas y las convertimos explícitamente al tipo factor en R. Esto es fundamental para que el software las trate correctamente durante el modelado, evitando interpretaciones incorrectas como variables numéricas continuas.

Las variables categóricas incluían idiomas, características demográficas, estados civiles, niveles educativos, indicadores de empleo y otras medidas cualitativas.

h. Eliminación NA's de la Variable Objetivo

La variable INDFMPIR presentaba 418 valores faltantes (7.55% del dataset original de 5539 filas). En lugar de imputar estos valores con la mediana, decidimos eliminar estas observaciones directamente. Esta decisión se justifica porque: imputar la variable objetivo introduce sesgo artificial en el modelo, ya que "fabrica" datos que no fueron observados, afectando la calibración de los coeficientes. Además un 7.55% de pérdida es aceptable y deja un tamaño de muestra robusto de 5121 observaciones. Finalmente eliminar filas incompletas es la práctica estándar en regresión cuando el porcentaje de missing es moderado, garantizando integridad estadística. El resultado es un dataset final completamente observado en la variable objetivo, listo para el modelado.

i. Dataset Final

El proceso completo de pre-procesamiento resulta en un dataset optimizado, con:

- **20 variables seleccionadas** basadas en relevancia correlacional y teórica
- **Datos completos** en todas las variables críticas para el modelado
- **Homogeneidad** en la representación de valores faltantes
- **Tipificación correcta** de variables (factores vs. numéricas)
- **Imputación robusta** de la variable objetivo


Este dataset limpio y estructurado constituyó la base para todos los análisis posteriores, incluyendo estadísticas descriptivas, construcción de modelos predictivos y validación estadística.

ii. Univariate Descriptive Statistics

Después del preprocesamiento, hacemos un breve análisis descriptivo univariable a través de la función de summary, y las gráficas de distribución de las variables preprocesadas y las procesadas y seleccionadas para los modelos que llevaremos a cabo.

El análisis univariado descriptivo básico de las variables numéricas retenidas tras el preprocesamiento revela una diversidad de distribuciones que informan sobre la estructura de los datos seleccionados (NHANES).

Figura 02: Distribución de RIDAGEYR



Variables como RIDAGEYR (edad en años) exhiben distribuciones aproximadamente simétricas con baja asimetría (skewness = 0.44), facilitando el uso de técnicas paramétricas sin transformaciones adicionales.

Figura 03: Distribución de WTINT2YR





Figura 04: Distribución de INDFMPIR



En contraste, variables como WTINT2YR (peso de entrevista) e INDFMPIR (ratio de pobreza) presentan asimetrías positivas pronunciadas ($\text{skewness} > 1$), con colas largas hacia la derecha, lo que indica que podrían beneficiarse de transformaciones logarítmicas o del uso de estimadores robustos para reducir la influencia de valores extremos en el modelo.

Figura 05: Distribución de DMDFMSIZ






Figura 06: Distribución de DMDHRAGE



Otras variables, como DMDFMSIZ (tamaño de la familia) y DMDHRAGE (edad del cabeza de familia), presentan distribuciones discretas o moderadamente sesgadas, reflejando patrones demográficos típicos.

Figura 07: Distribución de RIDSTATR



Variables binarias o categóricas numéricas, como RIDSTATR (estado de entrevista/examen), tienen baja variabilidad, con valores concentrados en categorías dominantes. En conjunto, estas características resaltan la necesidad de evaluar la normalidad y el sesgo para detectar posibles distorsiones en las relaciones entre variables, priorizando aquellas con distribuciones más estables que faciliten una modelización lineal fiable.

iii. Bivariate Descriptive Analysis

Para ver la relación entre nuestras variables decidimos escoger la variable binaria objetivo que usaremos posteriormente para nuestro modelo binario, de esta manera podemos observar la relación entre nuestras columnas y esta variable.

La variable escogida fue DMQMILIZ , e indica si el individuo ha servido en activo en las Fuerzas Armadas, Guardia o Reservas de EE. UU.

- $f = 1$: Ha servido en activo.
- DMQMILIZ = 0: No ha servido.

La parte verde en estos gráficos representa la proporción de personas que han servido en el ejército dentro de cada categoría. Nos muestra qué porcentaje de gente en cada grupo tiene experiencia militar.


Cuando la parte verde es grande, significa que un alto porcentaje de personas en esa categoría han servido. Cuando es pequeña, significa que muy pocas personas en ese grupo han tenido experiencia militar. La parte roja, por el contrario, representa a quienes no han servido.

De esta forma, comparando el tamaño de la sección verde entre diferentes categorías, podemos ver dónde la probabilidad de haber servido es mayor o menor. Un grupo con mucho verde indica una alta prevalencia de servicio militar, mientras que un grupo casi todo rojo sugiere que el servicio militar es poco común en esa población.

1. RIAGENDR (género)

- Los hombres presentan una probabilidad significativamente mayor de haber servido.
- Entre las mujeres, la probabilidad es muy baja.

Figura 08: Distribución de RIAGENDR





2. RIDAGEYR y DMDHRAGE (edad del participante y del cabeza de hogar)

- Las distribuciones de la clase 1 (personas que han servido) están desplazadas hacia edades mayores.
- En general, a mayor edad, mayor probabilidad de haber servido.

Figura 09: Distribución de RIDAGEYR





Figura 10: Distribución de DMDHRAGE



3. DMDBORN4 (nacido en EE. UU.) y DMDCITZN (ciudadanía)

- Nacer en EE. UU. y ser ciudadano estadounidense se asocian con una probabilidad sustancialmente más alta de servicio militar.
- Los nacidos fuera del país o sin ciudadanía presentan menor probabilidad.

Figura 11: Distribución de DMDBORN4





Figura 12: Distribución de DMDCITZN




4. SIALANG (idioma de la entrevista) y SIAINTRP (uso de intérprete)

- Entrevistas realizadas en inglés y sin intérprete muestran una alta probabilidad de DMQMILIZ=1.
- Entrevistas en español o con intérprete se asocian con una probabilidad baja.

Figura 13: Distribución de SIALANG




Figura 14: Distribución de SIAINTRP



5. DMDHREDU (nivel educativo)

- Se observa un gradiente suave: las personas con educación media o superior tienen mayor probabilidad de haber servido que aquellas con niveles educativos bajos.
- No hay saltos bruscos entre categorías.


Figura 15: Distribución de DMDHREDU



6. RIDRETH3 (raza/origen étnico)

- La probabilidad de haber servido es mayor entre personas **no hispánicas blancas** o **no hispánicas negras**.
- Es menor entre **asiáticos no hispánicos** y **grupos hispanos**.


Figura 16: Distribución de RIDRETH3



7. DMDFMSIZ (tamaño de la familia)

- Las personas que han servido tienden a pertenecer a familias ligeramente más pequeñas.
- No obstante, el solapamiento entre grupos es alto, por lo que el efecto es débil.


Figura 17: Distribución de DMDFMSIZ



8. DMDHRGND (género del cabeza de hogar)

- Cuando el cabeza de hogar es hombre, la probabilidad de haber servido es mayor.

Figura 18: Distribución de DMDHRGND




a. Interacciones de las Variables

Para comprobar si existen interacciones relevantes entre las variables del modelo, realizamos un análisis visual exploratorio de las combinaciones más prometedoras.

El objetivo es identificar si el efecto de una variable sobre el nivel de ingresos familiares (INDFMPIR) cambia dependiendo del nivel de otra variable, es decir, si el impacto de una característica depende de otra.

Comenzamos creando gráficos comparativos y boxplots que muestran cómo se comporta INDFMPIR en distintas combinaciones de factores. Por ejemplo, analizamos si el idioma de la entrevista (SIALANG) y el uso de intérprete (SIANTRP) parecían influir conjuntamente en los ingresos.

Figura 19: Plots SIALANG y SIANTRP




Como se puede ver no se observa ninguna interacción aparente entre estas variables.

Después, examinamos otras posibles combinaciones que teóricamente podían tener interacción, como:

- Educación × Género
- Lugar de nacimiento × Idioma
- Educación × Idioma
- Lugar de nacimiento × Ciudadanía
- Uso de intérprete × Ciudadanía

En algunos de estos gráficos, por ejemplo Educación × Género se observan diferencias aparentes entre grupos, lo que visualmente sugiere una posible interacción.


Figura 20: Educación x Género sobre INDFMPIR



Sin embargo, al incluir estas combinaciones en modelos estadísticos formales, la mayoría no resultan estadísticamente significativas al incluirlas en los posteriores modelos.

La única interacción que muestra significancia estadística real es la de Educación × Idioma (DMDEDUC2 × SIALANG). Esta relación indica que el efecto del nivel educativo sobre los ingresos familiares varía según el idioma en que se realizó la entrevista.

Figura 21: Plot Educación x Language



En resumen, aunque los gráficos iniciales parecen mostrar varias interacciones posibles, las pruebas estadísticas demostraron que solo una (Educación × Idioma) tiene relevancia real en el modelo. Este proceso evidencia la importancia de combinar la observación visual con el análisis estadístico: lo que a primera vista puede parecer un patrón interesante, no siempre se sostiene al evaluar su significancia matemática.

iv. Conclusiones

a. Estructura de Variables y Sesgo Univariado

Las variables numéricas muestran distribuciones heterogéneas:

- Distribuciones estables: La variable RIDAGEYR (edad) es aproximadamente simétrica, lo que la hace apta para modelos paramétricos.

- Asimetría pronunciada: Variables clave como WTINT2YR (peso de entrevista) e INDFMPIR (ratio de pobreza) presentan una fuerte asimetría positiva, con colas largas hacia la derecha. Esta característica exige el uso de transformaciones logarítmicas o estimadores robustos para estabilizar la varianza y reducir la influencia de outliers en el modelo.
- Baja variabilidad: Variables categóricas como RIDSTATR (estado de examen) muestran una variabilidad muy baja, concentrándose en categorías dominantes.

b. Relaciones Bivariadas y Detección de Features del modelo binario

El análisis bivariado respecto a la variable objetivo latente el servicio militar (DMQMILIZ) identificó *features* con alta capacidad discriminativa:

- Factores demográficos clave: Los hombres (RIAGENDR) y las personas de mayor edad (RIDAGEYR) tienen una probabilidad significativamente superior de haber servido.
- Contexto social: Nacer en EE. UU. (DMDBORN4) y realizar la entrevista en inglés y sin intérprete (SIALANG, SIAINTRP) están fuertemente asociados con una mayor probabilidad de servicio militar.

c. Interacciones de Features

La exploración de interacciones sobre la variable de resultado clave (INDFMPIR, ratio de pobreza) determinó la necesidad de incluir términos de interacción en el modelo.

- Interacción significativa: La única interacción estadísticamente relevante fue Educación × Idioma ($DMDEDUC2 \times SIALANG$). Esta relación indica que el efecto del nivel educativo sobre los ingresos familiares no es constante, sino que varía dependiendo del idioma en que se realizó la entrevista.

d. Final Thoughts

La modelización requerirá un preprocesamiento cuidadoso para manejar el sesgo en variables como INDFMPIR y la incorporación explícita de la interacción Educación × Idioma para capturar la complejidad real de la relación con los ingresos familiares.

3. Generalized Linear Models (GLMz)

i. Model fitting

a. Modelo 1 (familia gaussiana, link identidad)

Como primer paso, probamos un modelo lineal generalizado utilizando la familia gaussiana con enlace identidad. A pesar de que sabíamos de antemano que esta elección probablemente no sería la más adecuada, consideramos importante evaluar su desempeño como punto de partida.

La razón principal de esta expectativa es que la variable objetivo (*INDFMPIR*, que representa el índice de ingresos respecto al umbral de pobreza) no sigue una distribución normal. En particular, se observa una fuerte acumulación de valores en 5, debido a que el conjunto de datos agrupa todos los valores de 5 en adelante como “5 o más”. Esta naturaleza genera una distribución asimétrica con cola corta, lo que rompe uno de los supuestos básicos del modelo gaussiano.

El modelo inicial estimado fue:

```
None  
mlgz <- glm(INDFMPIR ~ . - DMQMILIZ, dd, family = gaussian(link=identity))  
summary(mlgz)
```

Como veremos posteriormente, la [validación del modelo](#) nos dejó con la necesidad de probar con nuevos modelos, que se definen a continuación.

b. Modelo 2 (familia gaussiana, link log)

A continuación, ajustamos un nuevo modelo pero en este caso cambiando la familia link a un link logarítmico, para observar si existía alguna mejora sustancial que nos aportará un modelo que se ajustará adecuadamente a los datos.

El modelo ajustado fue:

```
None  
mlgz2 <- glm(INDFMPIR ~ .+ DMDEDUC2*SIALANG - DMQMILIZ, dd, family =  
gaussian(link=log))
```

El modelo mejoró sustancialmente, sin embargo, la validación demostró que no era suficiente, por lo que decidimos probar a cambiar la familia del modelo.

b. Modelo 3 (familia Gamma, link log)

Decidimos probar con la familia Gamma, que se suele ajustar debidamente a variables como ratios de pobreza.

El modelo ajustado con familia gamma y link log se ajustó de la siguiente manera:

```
None  
mlgz3 <- glm(INDFMPIR ~ . + DMDEDUC2*SIALANG, dd, family = Gamma(link=log))  
summary(mlgz3)
```

A partir de la validación del modelo, decidimos quedarnos con este modelo.

ii. Model Validation (deviance statistic)

a. Validación Numérica (Modelo 1)

Tras ajustar el primer modelo con familia gaussiana y link identidad, se obtuvo una desviación residual de 7425.5 con 5052 grados de libertad.

Cuando se evaluó su capacidad explicativa mediante el estadístico de la devianza,

$$(1 - pchisq(7425.5, 5052)) \approx 0$$

El resultado fue prácticamente 0, lo que indica que el modelo no consigue explicar adecuadamente la variabilidad de los datos. En otras palabras, las diferencias entre los valores observados y los predichos son demasiado grandes para ser atribuibles al azar, lo que sugiere un mal ajuste global.

b. Validación Numérica (Modelo 2)

En este caso, en el modelo con familia gaussiana y link logarítmico, se obtuvo una desviación residual de 7680.1 con 5048 grados de libertad.

$$(1 - pchisq(7680.1, 5048)) \approx 0$$

Cuando se evaluó su capacidad explicativa mediante el estadístico de la devianza el resultado fue de nuevo prácticamente 0, lo que indica que el modelo no consigue explicar adecuadamente la variabilidad de los datos.

c. Validación Numérica (Modelo 3)

Los resultados mejoraron significativamente con este nuevo modelo ajustado de familia Gamma y link logarítmico, debido a que nos proporcionó una desviación residual de 1906.1 en 5048 grados de libertad.


$$(1 - pchisq(1906.1, 5048)) \approx 1$$

Al comprobarlo mediante el estadístico de la devianza el resultado fue de prácticamente 1, lo que indica que el modelo se adapta adecuadamente y nos proporciona una gran explicabilidad de los datos.

d. Validación Gráfica (Modelo 1)

A pesar de los resultados numéricos desfavorables, se llevó a cabo una validación gráfica de los residuos para observar visualmente la calidad del ajuste. El gráfico de residuos mostró un patrón razonablemente disperso y sin grandes desviaciones sistemáticas, lo que sugiere que el modelo no estaba completamente desalineado con los datos.

Figura 22: Residuals del Modelo 1




Sin embargo, el hecho de que el estadístico de la devianza indicará un ajuste deficiente llevó a la conclusión de que, aunque la validación gráfica parecía decente, el modelo no era estadísticamente adecuado para los datos, que era el resultado esperado.

e. Validación Gráfica (Modelo 2)

En este caso se volvió a comprobar los residual plots del modelo para comprobar por validación gráfica el modelo ajustado con link logarítmico.

Figura 23: Residuals del Modelo 2




El gráfico de residuos volvió a mostrar un patrón razonablemente disperso y sin grandes desviaciones sistemáticas. Pero en este caso decidimos probar a cambiar la familia del modelo ajustado a una Gama para observar el nuevo ajuste del modelo y su precisión.

f. Validación Gráfica (Modelo 3)

Al realizar los residual plots de este modelo con familia gaussiana y link logarítmico, podemos observar que la varianza es significativamente peor que en los modelos anteriores, probablemente debido a la acumulación de datos debido a como está definida nuestra variable objetivo, y a la acumulación de valores en el 5.

Figura 24: Residuals del Modelo 3



Sin embargo, decidimos quedarnos con este último modelo debido a que el estadístico de la devianza nos proporciona un resultado mucho más positivo que en los otros modelos.

g. ANOVAS

Una vez ajustado el modelo, realizamos una prueba ANOVA para evaluar la importancia relativa de cada variable y explorar la posibilidad de simplificar el modelo. Comprobamos los tres modelos propuestos (Gaussiano, Gaussiano con enlace logarítmico y Gamma con enlace logarítmico) y encontramos que la significancia de las variables era similar en todos ellos. Esta consistencia nos permitió identificar cuáles eran verdaderamente necesarias y cuáles podrían ser redundantes.

Tabla 06: Resultados Prueba ANOVA

Variable	LR Chisq	Df	Pr(>Chisq)	Significancia
RIAGENDR	1.98	1	1.594.543	
RIDAGEYR	38.66	1	5,05E-07	***
RIDRETH3	229.19	5	< 2.2e-16	***
DMQMILIZ	0.02	1	8.890.934	
DMDBORN4	1.00	1	3.174.280	
DMDCITZN	2.99	1	835.421	.
DMDDEDUC2	105.30	4	< 2.2e-16	***
SIALANG	9.57	1	19.770	**
SIINTRP	6.73	1	94.758	**
DMDFMSIZ	6.12	1	133.553	*
DMDHHSZA	181.32	1	< 2.2e-16	***
DMDHHSZB	110.70	1	< 2.2e-16	***
DMDHHSZE	3.93	1	474.130	*
DMDHRGND	10.31	1	13.196	**
DMDHRAGE	1.82	1	1.774.029	
DMDHRBR4	0.97	1	3.239.557	
DMDHREDU	152.27	4	< 2.2e-16	***
DMDHRMAR	244.90	5	< 2.2e-16	***
WTINT2YR	466.36	1	< 2.2e-16	***
DMDDEDUC2:SIALANG	20.17	4	4.633	**

Sin embargo, los resultados mostraron que, aunque algunas variables no alcanzaron significancia estadística, su contribución conceptual seguía siendo valiosa.

Aunque el modelo incluye algunas variables que no alcanzan significancia estadística, decidimos mantenerlas en lugar de eliminarlas. Esta decisión se fundamenta en que estas variables capturan características demográficas y sociales esenciales del individuo que, más allá de su valor estadístico inmediato, representan dimensiones importantes del individuo.

Variables como el género, la etnicidad, el lugar de nacimiento, la ciudadanía, el tamaño de la familia y la estructura del hogar son características intrínsecas que definen el perfil de los participantes. Aunque algunas no muestren efectos estadísticamente significativos en este análisis específico, su inclusión mejora la validez conceptual del modelo y reduce el riesgo de sesgo de omisión variable.

En otras palabras, estas no son variables "ruidosas" o arbitrarias, sino factores demográficos fundamentales que tiene sentido controlar en cualquier análisis sobre el ratio de ingresos, incluso cuando su contribución estadística es modesta.

iii. Model Interpretation

A partir de nuestro modelo con familia Gamma y link logarítmico, analizaremos los diferentes coeficientes para observar cómo afectan las diversas características de los individuos en la variable objeto de estudio, el ratio de pobreza del individuo.

1. Género (RIAGENDR)

El coeficiente para la variable categórica de género, respecto a la categoría inicial (es decir, diferencia entre ser hombre o mujer) es de -0.0247 ($p = 0.159$, no significativo). Si observamos el porcentaje aplicando $\exp(-0.0247) \approx 0.976$ podemos deducir que el hecho de cambiar de la primera a la segunda categoría reduce el porcentaje en un -2.4%.

Aunque no es estadísticamente significativo, el modelo sugiere que las mujeres tienen un ratio de ingresos aproximadamente -2.4% menor que los hombres, manteniendo constantes las demás variables. El efecto es pequeño y no robusto, lo que indica que no se detectan diferencias relevantes de ingreso por género una vez controlados otros factores estructurales.

2. Edad (RIDAGEYR)

El coeficiente para la variable de la edad es de 0.00533 ($p < 0.001$, altamente significativo). Si observamos el porcentaje aplicando $\exp(0.00533) \approx 1.0053$ podemos deducir que por cada año adicional de la persona aumenta un +0.53% la variable objetivo.

Esto significa que cada año adicional de edad se asocia con un aumento de aproximadamente 0.53% en el ratio INDFMPIR. Una persona de 50 años tendría en promedio un 17% más de ingreso relativo que una de 20 años, manteniendo las demás variables constantes. La edad muestra una relación positiva y estadísticamente robusta con el nivel económico.

3. Etnicidad (RIDRETH3)

Tabla 07: Categoría de referencia: Mexican American (1).

Grupo	Coeficiente	exp(coef)	Cambio (%)	Significancia
Other Hispanic (2)	+0.0557	1.057	+5.7%	No significativo
Non-Hispanic White (3)	-0.309	0.734	-26.6%	$p < 2e-16$
Non-Hispanic Black (4)	-0.0089	0.991	-0.9%	No significativo
Non-Hispanic Asian (6)	+0.225	1.252	+25.2%	$p < 1e-7$
Other/Multi-racial (7)	-0.138	0.871	-12.9%	$p = 0.009$

Como podemos observar, hay diferencias étnicas significativas. Los asiáticos no hispanos presentan un ingreso relativo 25% superior al grupo de referencia, mientras que los blancos no hispanos tienen un ratio 26.6% menor. Estas diferencias sugieren que, tras controlar por educación, edad y otras características, las brechas por grupo étnico persisten, aunque no siguen los patrones tradicionales de desigualdad observados en otros contextos.

4. Nivel Educativo (DMDEDUC2)

Tabla 08: Referencia: menos de 9 años de educación.

Nivel educativo	Coef.	exp(coef)	Cambio (%)	Signif.
High school graduate (2)	0.197	1.218	+21.8%	$p < 0.001$
Some college (3)	0.334	1.396	+39.6%	$p < 0.001$
Associate degree (4)	0.434	1.543	+54.3%	$p < 0.001$
College graduate or above (5)	0.571	1.770	+77.0%	$p < 0.001$

La educación es el factor más potente del modelo. Cada nivel adicional de estudios aumenta de forma significativa el ratio de ingresos: terminar secundaria eleva el ingreso relativo un 22%, y tener título universitario casi lo duplica. Esto reafirma que la educación actúa como un factor protector frente a la pobreza relativa.

5. Idioma e Intérprete (SIALANG, SIAINTRP)

El hecho de cambiar a SIALANG2 (haber hecho entrevista en español respecto a haberla hecho en inglés) nos da un coeficiente de $+0.0526$, si lo expresamos con $\exp(0.0526)$ podemos observar que nos da 1.054 , es decir, aumenta un $+5.4\%$. Sin embargo, este coeficiente no tiene mucha significancia estadística.

El hecho de tener o no un intérprete presente (SIAINTRP2) nos da un coeficiente de $+0.125$, transformado $\exp(0.125) = 1.133$, lo que nos indica que aumenta un $+13.3\%$ con un p valor de 0.008 , aporta un poco de relevancia estadística.

Podemos deducir que el idioma español no muestra efecto negativo sobre el ingreso, pero la presencia de intérprete sí se asocia a un incremento del 13% . Esto podría indicar que los hogares que requieren intérprete no necesariamente están en situación económica más baja, debido a que pueden permitirse usar un intérprete.

6. Tamaño y Composición del Hogar

- DMDFMSIZ (tamaño del hogar): coef. = $+0.0198$ transformando con $\exp(0.0198) = 1.020$, es decir, aumenta un $+2.0\%$ ($p = 0.013$). Este resultado muestra significancia estadística moderada.
- DMDHHSZA (niños <5 años): coef. = -0.219 transformando con $\exp(-0.219) = 0.803$, lo que indica una reducción del -19.7% ($p < 2e-16$). Este es el factor con mayor impacto negativo y altamente significativo.
- DMDHHSZB (niños $6-17$ años): coef. = -0.128 transformando con $\exp(-0.128) = 0.880$, representando una disminución del -12.0% ($p < 2e-16$). También presenta una significancia estadística muy alta.
- DMDHHSZE (adultos ≥ 60 años): coef. = -0.030 transformando con $\exp(-0.030) = 0.970$, mostrando una reducción del -2.9% ($p = 0.047$). Tiene significancia estadística pero con menor relevancia práctica.

Podemos ver que los hogares con más miembros tienden a tener ingresos totales algo mayores ($+2\%$), efecto atribuible al aumento del número de potenciales perceptores de ingresos. Sin embargo, la presencia de dependientes jóvenes reduce considerablemente el ingreso relativo. Los niños menores de 5 años generan el impacto negativo más pronunciado (-19.7%), probablemente debido al incremento significativo de gastos de cuidado y la menor disponibilidad laboral de los adultos para trabajar. Los niños en edad escolar también impactan negativamente (-12.0%), aunque en menor medida, mientras que la presencia de adultos mayores muestra un efecto modesto (-2.9%), sugiriendo que la composición demográfica del hogar es un determinante importante de los ingresos relativos.

7. Género y Edad del Cabeza de Hogar

El hecho de que el hogar esté encabezado por una mujer (DMDHRGND2) nos da un coeficiente de -0.0563 , que transformado con $\exp(-0.0563)$ nos proporciona 0.945 , es decir, disminuye un -5.5% ($p = 0.001$). Este resultado presenta una significancia estadística considerable, indicando que los hogares con jefatura femenina tienen ingresos un 5.5% menores en promedio, lo que sugiere la existencia de brechas estructurales persistentes en términos de capacidad económica y acceso a oportunidades de generación de ingresos.

Por otro lado, la edad del cabeza del hogar (DMDHRAGE) nos proporciona un coeficiente de -0.0013 , que transformado resulta en $\exp(-0.0013) = 0.999$, representando una reducción prácticamente nula del -0.13% ($p > 0.05$). Este coeficiente no presenta significancia estadística relevante, lo que nos indica que la edad de la persona que encabeza el hogar no tiene un efecto notorio sobre los ingresos en este contexto particular. Podemos deducir, por tanto, que mientras la jefatura femenina se asocia de manera clara con menores ingresos relativos, la edad del cabeza del hogar no constituye un factor determinante en la variación de los ingresos del grupo estudiado.

8. Educación del Cabeza de Hogar (DMDHREDU)

Tomando como referencia los hogares cuyo cabeza tiene menos de 9 años de educación, se observa que a medida que aumenta el nivel educativo del cabeza del hogar, el ratio de ingresos mejora de manera notablemente progresiva. Específicamente, aquellos hogares cuyo cabeza es graduado de high school (nivel 2) presentan ingresos un $+8.7\%$ mayores. Este incremento se reduce considerablemente en los hogares con algo de educación universitaria (nivel 3), alcanzando un $+17\%$, y continúa ampliándose con aquellos que poseen un associate degree (nivel 4), que muestran un $+29.8\%$ de mejora. El efecto más pronunciado se observa en los hogares cuyo cabeza es graduado universitario (nivel 5), donde los ingresos aumentan hasta un $+65.5\%$ en comparación con la categoría de referencia.

Estos resultados demuestran que el nivel educativo del cabeza de hogar constituye un predictor fuerte e independiente del bienestar económico del hogar, con un patrón de retorno creciente a medida que se alcanzan niveles educativos más altos. Esta relación refuerza el patrón ya observado en la educación individual y subraya la importancia crítica de la inversión en capital humano como determinante fundamental de la capacidad económica y el bienestar material de los hogares.

9. Estado Civil del Cabeza de Familia (DMDHRMAR)

Tabla 09: Referencia: casado (1)

Estado civil	Coef.	exp(coef)	Cambio (%)
Viudo (2)	-0.189	0.828	-17.2%
Divorciado (3)	-0.294	0.745	-25.5%
Separado (4)	-0.305	0.737	-26.3%
Nunca casado (5)	-0.354	0.702	-29.8%
Viviendo en pareja (6)	-0.174	0.840	-16.0%

Podemos observar que todas las categorías distintas a “casado” muestran reducciones significativas en el ratio de ingresos. Estar casado aparece como un factor protector sólido frente a la pobreza relativa, lo que sugiere que los hogares con dos adultos estables presentan ventajas económicas sostenidas.

10. Interacción Educación × Idioma (DMDEDUC2 × SIALANG)

La interacción es globalmente significativa ($p < 0.05$). Los efectos para entrevistados en español muestran que la ventaja de la educación se atenúa:

Tabla 10: Nivel educativo x Español

Nivel educativo × Español	Coef. interacción	Reducción del efecto
High school graduate	-0.145	-13.5% (marginamente significativo)
Some college	-0.296	-25.7%
Associate degree	-0.381	-31.7%
College graduate	-0.349	-29.5%

Esto lo podemos interpretar de la siguiente manera: una persona entrevistada en inglés con educación universitaria tendría un efecto de +77%. Si fue entrevistada en español, su efecto total sería $\exp(0.571 - 0.349) = \exp(0.222) \approx +24.8\%$.

Esto nos indica que la educación sigue siendo un fuerte factor protector, pero su impacto se reduce notablemente entre quienes enfrentan barreras lingüísticas, reflejando cómo la educación se convierte de manera desigual en capital.

11. Ponderación (WTINT2YR)

El peso de diseño de la encuesta (coeficiente: $8.19e-06$) es altamente significativo ($p < 2e-16$), lo que indica que este factor juega un papel crucial en los resultados.

Este término refleja cómo la encuesta fue diseñada para asegurar que los resultados sean representativos de la población general, es decir, que los datos obtenidos no solo describan a quienes respondieron, sino que puedan extrapolarse y reflejar las características reales de toda la población estudiada.

12. Conclusiones Generales

El modelo confirma que la educación y el estado civil son los factores más determinantes del nivel de ingresos relativo al umbral de pobreza. También se observan efectos negativos claros asociados con la presencia de hijos pequeños y con hogares encabezados por mujeres. La etnicidad y el idioma introducen matices importantes: los asiáticos no hispanos tienen ventaja económica significativa, mientras que el uso del español, combinado con menor acceso educativo, reduce parcialmente los beneficios de la educación. En conjunto, el modelo captura de manera robusta los principales determinantes socioeconómicos del bienestar económico dentro de la muestra.

iv. Presentación Modelo Binario

La variable DMQMILIZ indica si un individuo ha servido activamente en las Fuerzas Armadas de Estados Unidos (0 = no, 1 = sí). Antes de ajustar el modelo, se eliminaron las observaciones con datos faltantes para esta variable y para todas las covariables relevantes, de forma que el análisis se realizará sobre un conjunto completamente observado.

El conjunto de datos presentaba un fuerte desbalance de clases: aproximadamente 4682 observaciones en la categoría "no ha servido" (0) frente a solo 494 observaciones en la categoría "sí ha servido" (1). Este desbalance representa un problema conocido en modelado predictivo, ya que el algoritmo de regresión logística tiende a favorecer la predicción de la clase mayoritaria, subestimando la capacidad para identificar correctamente los casos de la clase minoritaria.

Para mitigar este problema, se implementó un submuestreo aleatorio de la clase mayoritaria. Específicamente, se seleccionó aleatoriamente un número de casos de la clase 0 igual al número de casos de la clase 1 (494 observaciones), de modo que ambas categorías tuvieran exactamente el mismo peso. Esto generó un dataset balanceado con 494 individuos en cada categoría, permitiendo que el modelo se ajusta bajo una distribución equilibrada de clases.

La ventaja de este enfoque es que permite evaluar cómo el desbalanceo afectaba al modelo original, y si los resultados se mantenían robustos ante cambios en la composición de la muestra.

v. Binary Model fitting

Se estimaron dos modelos, ambos con la variable dependiente DMQMILIZ:

a. Modelo 1 (balanced data)

Modelo 1 (Balanceado): Ajustado sobre el dataset con clases equilibradas (494 observaciones de cada clase). Incluimos todas las variables explicativas disponibles.

```
None  
summary(mb_balanced <- glm(DMQMILIZ ~ ., dd_binary_balanced,  
family=binomial(link='logit')))
```

b. Modelo 2 (unbalanced data)

Modelo 2 (Desbalanceado): Ajustado directamente sobre los datos originales con su distribución natural (4682 casos de clase 0, 494 de clase 1). También incluyó todas las variables disponibles.

```
None  
summary(mb <- glm(DMQMILIZ ~ ., dd_binary, family=binomial(link='logit')))
```

En ambos casos se utilizó la función GLM con familia binomial y enlace logit.

vi. Binary Model Validation

a. AUC - ROC validation

Para evaluar la capacidad discriminativa de ambos modelos calculamos las curvas ROC (Receiver Operating Characteristic) y el área bajo la curva (AUC). El AUC mide la probabilidad de que el modelo clasifique correctamente un caso positivo y uno negativo seleccionados aleatoriamente, con valores cercanos a 1 indicando excelente desempeño y valores cercanos a 0.5 reflejando clasificación aleatoria.

Resultados:

Modelo balanceado: AUC = 0.9038

Modelo desbalanceado: AUC = 0.9085

Ambos modelos alcanzaron un AUC superior a 0.90, demostrando una excelente capacidad para distinguir entre individuos que sirvieron o no en las Fuerzas Armadas. La diferencia entre ambos es de apenas 0.0047, siendo prácticamente despreciable.

b. Validación Gráfica

El examen visual de los residual plots reveló diferencias claras entre los enfoques:


En el modelo balanceado, los residuos se concentran alrededor de cero con una varianza moderada y controlada, indicando un ajuste más homogéneo y una menor influencia de valores extremos.

En el modelo desbalanceado, los residuos muestran mayor dispersión y presencia de valores atípicos más pronunciados, reflejando una cierta sensibilidad a los casos extremos y heterocedasticidad moderada.

A pesar de estas diferencias en la dispersión, ninguno de los modelos evidencia un patrón sistemático de error, lo que sugiere una especificación correcta en ambos casos.


Balanced:

Figura 25: Balanced Predictor Lineal



Unbalanced:

Figura 26: Unbalanced Predictor Lineal



c. Simplificación modelo binario

Una vez ajustados los modelos completos, se realizó un análisis de varianza (ANOVA) para evaluar la importancia relativa de cada variable e identificar oportunidades de simplificación.

El ANOVA Tipo II reveló que muchas variables no alcanzaron significancia estadística en ninguno de los dos modelos (balanceado y desbalanceado). Esto indicaba que existía la posibilidad de crear un modelo más parsimonioso sin sacrificar capacidad predictiva.

Tabla 11: Resultados ANOVA Test 2

Variable	LR Chisq	Df	Pr(>Chisq)	Significancia
RIAGENDR	197.784	1	< 2.2e-16	***
RIDAGEYR	40.205	1	2,29E-07	***
RIDRETH3	24.059	5	2.115	***
DMDBORN4	1.655	1	1.982.179	
DMDCITZN	17.471	1	2,92E-02	***
DMDEDUC2	20.140	4	4.686	***
SIALANG	6.678	1	97.635	**
SIAINTRP	63	1	8.011.425	
DMDFMSIZ	253	1	6.148.428	
DMDHHSZA	60	1	8.061.234	
DMDHHSZB	10	1	9.216.309	
DMDHHSZE	133	1	7.157.126	
DMDHRGND	44	1	8.340.955	
DMDHRAGE	5.411	1	200.128	*
DMDHRBR4	27	1	8.683.717	
DMDHREDU	7.744	4	1.014.217	
DMDHRMAR	10.012	5	748.836	.
WTINT2YR	47	1	8.279.021	
INDFMPIR	6.039	1	139.918	*

Se ajustó un modelo nuevo reducido incluyendo solo las variables más relevantes: RIAGENDR, RIDAGEYR, RIDRETH3, DMDCITZN, DMDEDUC2 y SIALANG:

None

```
summary(mb2_balanced <- glm(DMQMILIZ ~ + RIAGENDR + RIDAGEYR + RIDRETH3 +
DMDCITZN + DMDEDUC2 + SIALANG, dd_binary_balanced,
family=binomial(link='logit')))
```

La comparación estadística entre el modelo completo y el reducido (mediante anova) mostró un p-valor de 0.0658, que es mayor a 0.05. Esto significa que no hay diferencia significativa entre ambos modelos: el modelo simplificado retiene prácticamente toda la información del modelo completo sin perderla de manera estadísticamente relevante.

Analysis of Deviance Table

```
Model 1: DMQMILIZ ~ RIAGENDR + RIDAGEYR + RIDRETH3 + DMDBORN4 + DMDCITZN +
  DMDEDUC2 + SIALANG + SIAINTRP + DMDFMSIZ + DMDHHSZA + DMDHHSZB +
  DMDHHSZE + DMDHRGND + DMDHRAGE + DMDHRBR4 + DMDHREDU + DMDHRMAR +
  WTINT2YR + INDFMPIR
Model 2: DMQMILIZ ~ +RIAGENDR + RIDAGEYR + RIDRETH3 + DMDCITZN + DMDEDUC2 +
  SIALANG
Resid. Df Resid. Dev  Df Deviance Pr(>Chi)
1      956      715.41
2      975      744.42 -19  -29.014  0.06576 .
```

Además, el modelo reducido mantuvo un AUC de 0.905 cuando se evaluaba sobre el conjunto de datos original (desbalanceado), confirmando que la simplificación no comprometía la capacidad predictiva, sumado a que los residual plots mostraban un comportamiento muy similar al modelo anterior.

d. Resumen

El análisis comparativo entre modelos balanceados y desbalanceados, así como entre modelos completos y simplificados, demuestra que el desbalanceo de clases original afectaba la interpretabilidad del modelo pero no comprometía significativamente su rendimiento predictivo. Además, el modelo simplificado (con seis variables) funciona prácticamente igual que el modelo completo (con diecinueve variables), pero ofrece mayor parsimonia e interpretabilidad. Ambos enfoques convergen en conclusiones similares respecto a qué variables son importantes para predecir la participación en el servicio militar.

Por estas razones, seleccionamos el modelo reducido como la versión final para la interpretación, ya que ofrece un equilibrio óptimo entre capacidad predictiva, estabilidad estadística y facilidad de interpretación.

vii. Interpretación Modelo Binario

Durante la interpretación del modelo binario con datos balanceados y con complejidad reducida, nos surgió un problema de quasi-separación, es decir separación casi perfecta en una de las variables, ciudadanía (DMDCITZN)

El coeficiente para no ciudadanos (DMDCITZN2) era de -17.22 con un error estándar gigantesco (≈ 566.9) $\rightarrow \exp(-17.22) \approx 3.3e-8$.

Esto es signo de separación completa o casi completa: en los datos balanceados prácticamente no hay no-ciudadanos que hayan declarado haber servido, por lo que el estimador es inestable.

Nuestra solución ha sido crear un nuevo modelo con una regresión penalizada (firth regression). Este modelo nos dió un área debajo de la curva ROC de 0.9052. Sin embargo, no podemos ver los residual plots debido a las diferencias de los métodos entre librerías de definición del modelo de regresión penalizada.

El modelo resultante mantiene las mismas variables significativas que en el ajuste clásico, pero con coeficientes algo atenuados (más conservadores), lo cual es esperable tras la penalización.

1. Género (RIAGENDR)

El coeficiente para las mujeres (RIAGENDR2) es de -2.92 , que transformado con $\exp(-2.92)$ nos proporciona aproximadamente 0.054. Esto significa que, manteniendo el resto de factores constante, las mujeres tienen alrededor del 5.4% de las probabilidades de haber servido en el ejército en comparación con los hombres, o expresado de otra manera, los hombres presentan aproximadamente 18 veces más probabilidades de haber servido. Este efecto es altamente significativo ($p < 0.001$), lo que indica un resultado muy robusto y confiable. La magnitud de esta diferencia se alinea con lo esperado considerando las diferencias históricas en las políticas de reclutamiento y acceso al servicio militar, donde históricamente ha habido restricciones o limitaciones en la participación de las mujeres. Este patrón refleja cómo factores estructurales e históricos del sistema militar han generado disparidades profundas en la composición del personal que ha servido.

2. Edad (RIDAGEYR)

El coeficiente para la edad es de 0.0529, que transformado con $\exp(0.0529)$ nos proporciona aproximadamente 1.054. Esto significa que por cada año adicional de edad, las probabilidades de haber servido en el ejército aumentan en un 5.4%. Para ilustrar este efecto, una persona de 40 años tiene aproximadamente 2.4 veces más probabilidades de haber servido que una persona de 20 años, manteniendo las demás variables constantes. Este resultado es altamente significativo ($p < 0.001$), indicando un efecto claro y robusto. La magnitud del impacto es coherente con la lógica de acumulación de experiencia a lo largo de la vida, reflejando cómo a medida que las personas envejecen, aumenta la probabilidad de que hayan tenido la oportunidad de servir en algún momento de sus vidas.

3. Etnicidad (RIDRETH3)

Tomando como categoría de referencia a los Mexican American, se observan diferencias significativas en las probabilidades de haber servido según el origen étnico. Los Other Hispanic presentan un coeficiente de 1.36, que transformado con $\exp(1.36)$ nos proporciona aproximadamente 3.89, es decir, tienen probabilidades casi 4 veces mayores ($p \approx 0.005$). Los Non-Hispanic White muestran un coeficiente de 0.78, resultando en $\exp(0.78) \approx 2.17$, lo que representa probabilidades aproximadamente el doble ($p \approx 0.026$). Los Non-Hispanic Black presentan un coeficiente de 1.15, transformado en $\exp(1.15) \approx 3.16$, mostrando un efecto claramente positivo ($p \approx 0.002$). En contraste, los Non-Hispanic Asian tienen un coeficiente de -1.06 , que transformado resulta en $\exp(-1.06) \approx 0.35$, representando probabilidades un 65% menores respecto al grupo de referencia ($p \approx 0.038$). Finalmente, los Other/Multi-racial presentan un coeficiente de 1.31, equivalente a $\exp(1.31) \approx 3.71$, mostrando probabilidades significativamente más altas ($p \approx 0.020$).

En términos generales, se mantienen las diferencias étnicas observadas en análisis previos, aunque algo suavizadas. Los grupos Non-Hispanic Black, Other Hispanic y Other/Multi-racial muestran mayor probabilidad de servicio militar, mientras que los asiáticos no hispanos presentan una menor probabilidad relativa. Estas diferencias pueden reflejar variaciones en factores culturales, generacionales y en la composición migratoria de cada grupo, así como posibles diferencias en el acceso a la información sobre oportunidades de servicio o en las motivaciones para alistarse.

4. Ciudadanía (DMDCITZN)

El coeficiente para el estatus de ciudadanía es de -3.84 , que transformado con $\exp(-3.84)$ nos proporciona aproximadamente 0.021. Esto significa que los no ciudadanos tienen aproximadamente el 2% de las odds de haber servido respecto a los ciudadanos, es decir, unas 50 veces menos probabilidad de haber servido. Este resultado es altamente significativo ($p < 0.001$), indicando un efecto muy robusto y confiable. A diferencia de análisis previos donde el coeficiente era inestable, en este modelo el efecto se estima de forma controlada y robusta, permitiendo una interpretación más sólida.

El resultado es coherente con la lógica del acceso limitado al servicio militar para no ciudadanos, reflejando cómo los requisitos legales y de elegibilidad del sistema militar crean barreras sustantivas que prácticamente excluyen a esta población de la oportunidad de servir.

5. Nivel educativo (DMDEDUC2)

Tomando como categoría de referencia la educación básica, se observan diferencias progresivas en las probabilidades de haber servido según el nivel educativo alcanzado. Los graduados de high school presentan un coeficiente de 0.05, que transformado con $\exp(0.05)$ nos proporciona aproximadamente 1.05, aún así, no representa un efecto significativo estadísticamente. Sin embargo, aquellos con algo de educación universitaria muestran un coeficiente de 1.15, resultando en $\exp(1.15) \approx 3.16$, es decir, probabilidades tres veces mayores ($p \approx 0.048$). El efecto se acentúa considerablemente en quienes tienen un associate degree o educación universitaria parcial, con un coeficiente de 1.65 transformado

en $\exp(1.65) \approx 5.21$, representando probabilidades cinco veces mayores ($p \approx 0.005$), un efecto muy significativo. Los graduados universitarios presentan un coeficiente de 1.48, equivalente a $\exp(1.48) \approx 4.40$, también significativo ($p \approx 0.012$).

La probabilidad de haber servido aumenta de forma clara y progresiva con el nivel educativo, siendo especialmente pronunciado el salto hacia la educación postsecundaria. Aquellos con educación postsecundaria presentan probabilidades entre 3 y 5 veces mayores que quienes tienen solo educación básica. Este patrón podría reflejar diferencias generacionales en el acceso al servicio militar, variaciones en las oportunidades disponibles para distintos grupos educativos, o diferencias en la disposición a reportar y documentar experiencias de servicio militar según el nivel de escolarización.

6. Idioma de la entrevista (SIALANG)

El coeficiente para ser entrevistado en español (SIALANG2) es de -2.45 , que transformado con $\exp(-2.45)$ nos proporciona aproximadamente 0.086. Esto significa que las personas entrevistadas en español tienen alrededor del 8.6% de las probabilidades de haber servido respecto a las entrevistadas en inglés, es decir, unas 12 veces menos probabilidad de haber servido. Este resultado es significativo ($p \approx 0.005$), indicando un efecto grande y robusto que se mantiene incluso cuando se controlan otras variables. Esta gran diferencia probablemente está relacionada con la composición migratoria de la población, ya que quienes son entrevistados en español tienden a ser inmigrantes más recientes o de primera generación, quienes naturalmente tienen menor probabilidad de haber servido en el ejército estadounidense debido a su tiempo más limitado de residencia en el país o a su estatus de ciudadanía. El patrón refleja cómo los factores migratorios y de tiempo de permanencia en Estados Unidos son determinantes cruciales en el acceso histórico al servicio militar.

7. Conclusión general

Los resultados ofrecen una representación más estable y confiable de los factores asociados al servicio militar. El género, la edad, la educación y el idioma siguen siendo los predictores más relevantes en la determinación de quién ha servido, mientras que la etnicidad y la ciudadanía también muestran impactos significativos.

Aunque los ajustes técnicos mejoran la fiabilidad de las estimaciones, no modifican la interpretación sustantiva de los hallazgos. En términos prácticos, estos resultados proporcionan una fotografía robusta de cómo diferentes características demográficas, educativas y migratorias se asocian con la experiencia de servicio militar. Los patrones revelan que el acceso al servicio militar no es aleatorio, sino que responde a dinámicas claras ligadas a oportunidades históricas, restricciones legales y composición de la población según origen y ciudadanía. Las diferencias más pronunciadas se encuentran en el género —donde los hombres tienen probabilidades drásticamente mayores—, la ciudadanía —que prácticamente excluye a no ciudadanos— y el idioma —reflejando la brecha entre poblaciones migrantes recientes y establecidas—, mientras que factores como la educación y la edad muestran efectos progresivos pero menos extremos.

4. Time Series (TS)

i. Selección de Dataset

El análisis de series temporales requiere observaciones secuenciales a intervalos regulares. El dataset utilizado en análisis previos no cumplía este requisito. Por ello, adoptamos el conjunto de datos CPS ASEC de tasas de pobreza, que proporciona:

- Observaciones anuales consistentes desde 1959 hasta 2024 (65 años)
- Tasas de pobreza (PCTPOV) desagregadas por categoría demográfica (RACE_NAME)
- Cobertura completa de Estados Unidos

El dataset tiene las siguientes columnas:

Tabla 12: Descripción Dataset TimeSeries

Nombre de la columna	Descripción
PCTPOV	Tasa de pobreza en porcentaje para el grupo y el año (puntos porcentuales). Aproximadamente, $PCTPOV = 100 * POV / POP$.
POV	Número de personas en situación de pobreza (conteo) para el grupo y el año.
POP	Población total (denominador) para el grupo y el año.
time	Año de la estimación (anual).
RACE	Código numérico para la categoría demográfica (agrupación por raza/etnicidad).
us	Indicador geográfico 1 = Total de Estados Unidos (agregado nacional).
RACE_CODE	Código numérico de raza/etnicidad (misma codificación que RACE, incluido por compatibilidad).
RACE_NAME	Etiqueta legible para el grupo (por ejemplo, "Todas las razas", "Blanco", "Negro", "Hispano (de cualquier raza)", "Solo blanco, no hispano", "Solo asiático").

Un desafío importante surgió del cambio en 2002 en la clasificación racial del censo, que introdujo categorías como "White Alone, Not Hispanic". Para mantener la comparabilidad temporal, consolidamos todas las categorías en cinco grupos consistentes:

- Total (población general)
- White (blancos)
- Black (afroamericanos)
- Hispanic (hispanos/latinos)
- Asian (asiáticos)

Tabla 13: Armonización del Dataset

group	RACE_NAME	start_year	end_year	n_years
<i>All</i>	All Races	1959	2024	66
<i>Asian</i>	Asian Alone	2002	2024	23
<i>Asian</i>	Asian and Pacific Islander	1987	2001	15
<i>Black</i>	Black	1959	2001	37
<i>Black</i>	Black Alone	2002	2024	23
<i>Hispanic</i>	Hispanic (of any race)	1972	2024	53
<i>White</i>	White	1959	2001	43
<i>White</i>	White Alone, not Hispanic	2002	2024	23

Para "White" en años post-2002, priorizamos "White Alone, Not Hispanic" para excluir hispanos blancos y mantener grupos mutuamente exclusivos.

ii. Preguntas a Investigar

Nuestra pregunta central de investigación busca encontrar qué grupos demográficos experimentaron las dificultades económicas más severas durante cada recesión. Nos pareció interesante el hecho de hacer múltiples análisis de series temporales para diferentes rangos de tiempo para luego compararlos.

Textproto

¿Qué grupos demográficos experimentaron los incrementos más severos en pobreza durante cada crisis económica?

Definimos el impacto como el cambio en puntos porcentuales entre:

- Pico: La tasa de pobreza máxima observada durante la crisis
- Baseline: El promedio de las tasas de pobreza en los 3 años previos

Por ejemplo, si la tasa de pobreza hispana era 22% en promedio (1977-1979) y alcanzó 29.9% en 1982, el impacto fue +7.9 pp.

Tras investigar históricamente que recesiones serían interesantes, decidimos centrarnos en:

1. Recesión de Reagan: 1980-1983 (baseline: 1977-1979)
2. Crisis DotCom: 2001-2003 (baseline: 1998-2000)
3. Gran Recesión: 2008-2010 (baseline: 2005-2007)
4. Pandemia COVID-19: 2020-2021 (baseline: 2017-2019)

iii. Modelo Series Temporales

Para entender la dinámica general de la pobreza en EE.UU., desarrollamos un modelo ARIMA usando la serie "Total Population".


a. Transformación Logarítmica

Aplicamos

```
Rust
log(PCTPOV)
```

para estabilizar la varianza a lo largo de los 65 años de datos. Esta transformación es estándar cuando la variabilidad de una serie aumenta con su nivel.

Figura 27: Transformación Logarítmica



b. Diferenciación para Estacionariedad


La serie mostraba una raíz unitaria (tendencia no estacionaria), por lo que calculamos las diferencias de primer orden:

TypeScript

$$\Delta \log(\text{PCTPOV}_t) = \log(\text{PCTPOV}_t) - \log(\text{PCTPOV}_{t-1})$$

Esto nos da $d=1$ en la notación $\text{ARIMA}(p,d,q)$.

Figura 28: ACF y PACF Inicial



c. Identificación del Modelo

Analizando los gráficos ACF y PACF identificamos un patrón autorregresivo, lo que nos llevó a probar modelos $\text{ARIMA}(p,1,0)$. Comparamos dos candidatos:

- $\text{ARIMA}(3,1,0)$

$$AIC = -204.04$$

- $\text{ARIMA}(2,1,0)$

$$AIC = -205.87$$

Seleccionamos $\text{ARIMA}(2,1,0)$ porque:

- 1) Menor AIC
- 2) Todos los coeficientes son significativos ($t \approx 3.8$)

3) El tercer parámetro en ARIMA(3,1,0) no era significativo

d. Diagnóstico del Modelo

Verificamos que nuestro modelo cumple los supuestos necesarios:

- Residuos con varianza constante (sin heterocedasticidad)
- Residuos aproximadamente normales (gráfico Q-Q)
- No autocorrelación residual (test de Ljung-Box)
- No se requieren componentes estacionales (datos anuales)

Figura 29: Análisis de Residuais





Figura 30: Resultados de los Residuais

Haciendo los ACFs de los residuos, vemos la diferencia entre el valor real y el que predice el modelo.

Como se puede observar, no hay ningún valor que se desvíe excesivamente (el que más destaca se ve cerca del 15 de los ACF of Residuals, pero incluso ese es aceptable).




iv. Resultados y Validación

Calculamos el incremento en puntos porcentuales (pp) de pobreza para cada grupo durante cada crisis, comparando el pico con el baseline de 3 años previos.

Tabla 14: Resultados

Grupo	Reagan (80-83)	DotCom (01-03)	Gran Recesión (08-10)	COVID-19 (20-21)
All	+3.63	+0.53	+2.63	+0.07
White	+3.23	-0.03	+1.67	+0.17
Black	+4.73	+0.33	+2.83	-0.67
Hispanic	+7.97	-0.77	+5.20	-0.10
Asian	NA	+0.77	+1.97	+0.17

Figura 31: Heatmap de incrementos por crisis



a. Recesión de Reagan (1980-1983)

- **Hispanos: +8.0 pp (de 21.9% a 29.9% en 1982)**
- Negros: +4.7 pp (de 31.0% a 35.7% en 1983)
- Total: +3.6 pp (de 11.6% a 15.2% en 1983)

b. Crisis DotCom (2001-2003)

- **Asiáticos: +0.8 pp (de 11.0% a 11.8% en 2003)**
- Total: +0.5 pp (de 12.0% a 12.5% en 2003)
- Negros: +0.3 pp (de 24.1% a 24.4% en 2003)

c. Gran Recesión (2008-2010)


- **Hispanos: +5.2 pp (de 21.3% a 26.5% en 2010)**
- Negros: +2.8 pp (de 24.6% a 27.4% en 2010)
- Total: +2.6 pp (de 12.5% a 15.1% en 2010)

d. COVID-19 (2020-2021)

- **Asiáticos: +0.2 pp (de 9.1% a 9.3% en 2021)**
- Blancos: +0.2 pp (de 8.0% a 8.2% en 2020)
- Total: +0.1 pp (de 11.5% a 11.6% en 2021)

v. Conclusiones

Figura 32: Incremento de pobreza por crisis



Hallazgos Principales:

1. Vulnerabilidad Diferencial Persistente

La población hispana emerge como el grupo más vulnerable en recesiones "tradicionales" (Reagan: +8.0 pp; Gran Recesión: +5.2 pp), mientras que la población asiática muestra mayor sensibilidad en crisis sectoriales/de salud pública.

2. La Política Fiscal Importa

Los incrementos en COVID-19 fueron dramáticamente menores que en crisis previas, sugiriendo que las intervenciones fiscales agresivas pueden mitigar efectivamente los impactos en la pobreza.

3. Heterogeneidad por Tipo de Crisis

No existe un "grupo más vulnerable" universal, la vulnerabilidad depende del tipo de shock económico.

Limitaciones Metodológicas:


- Armonización de categorías censales

Nuestra consolidación de categorías raciales (especialmente post-2002) implica simplificación.

- Método pico-vs-baseline

Captura magnitud pero no velocidad de recuperación ni persistencia a largo plazo.

Figura 33: Poverty Rate by Group




5. PCA

El Análisis de Componentes Principales (PCA) constituye una técnica de reducción dimensional que permite sintetizar la variabilidad contenida en múltiples variables numéricas en un conjunto reducido de nuevas variables no correlacionadas, denominadas componentes principales. En el contexto de este análisis demográfico, el PCA se aplica exclusivamente sobre las variables numéricas del dataset, eliminando previamente todas las variables categóricas para garantizar la homogeneidad de la métrica de distancia empleada.

El procedimiento comienza con la estandarización de las variables numéricas, transformando cada medición al rango de media cero y desviación estándar unitaria. Esta normalización es esencial para que variables con escalas muy diferentes, como la edad medida en años versus pesos muestrales que alcanzan valores en decenas de miles, contribuyan de forma equivalente al análisis. Una vez estandarizados los datos, se aplica PCA para identificar las direcciones de máxima variabilidad, que se representan como combinaciones lineales de las variables originales. El resultado es un conjunto de componentes principales ordenados por la cantidad de varianza que capturan, permitiendo determinar cuántos componentes son necesarios para preservar la estructura esencial de los datos.

i. Screeplot: Selección del Número de Componentes Principales

El gráfico de sedimentación (screeplot) representa de forma gráfica la cantidad de varianza explicada por cada componente principal, ordenados de mayor a menor. Este gráfico es fundamental para determinar cuántas dimensiones son realmente necesarias para capturar la estructura de los datos:



a. Interpretación del Screeplot

El screeplot muestra un patrón donde los primeros componentes capturan proporciones muy significativas de la varianza total, mientras que los componentes sucesivos contribuyen de forma progresivamente menor. Específicamente:

El primer componente principal retiene el 30.6 por ciento de la varianza total, lo que indica que por sí solo captura casi un tercio de toda la información contenida en las diez variables numéricas originales. Este componente representa una dirección en el espacio original donde los datos varían más significativamente.

El segundo componente añade un 18 por ciento adicional de varianza explicada, alcanzando en conjunto con el primero un acumulado del 48.6 por ciento. Esta contribución

sustancial indica que existe una segunda dirección independiente que contiene información relevante no capturada por el primer eje.

El tercer componente contribuye con un 13.6 por ciento, elevando el total acumulado a aproximadamente el 62 por ciento. A este punto, los tres primeros componentes en conjunto ya explican casi dos tercios de la variabilidad total del dataset.

A partir del cuarto componente en adelante (10.1 por ciento, 9.9 por ciento, 9.6 por ciento, etc.), la tasa de aportación de varianza desciende de forma muy notable. La pendiente se suaviza gradualmente, indicando que los componentes adicionales contribuyen cada vez menos información nueva.

b. Criterio de Selección

El criterio clásico para determinar el número óptimo de componentes consiste en identificar el "codo" en la curva, es decir, el punto donde comienza a observarse un cambio abrupto en la pendiente. En este caso, el codo es particularmente evidente entre el tercer y cuarto componentes. Aunque no hay un umbral matemático universal, los criterios comúnmente empleados sugieren retener componentes hasta que la varianza acumulada alcance entre el 70 y el 80 por ciento, o bien hasta que la aportación de cada componente adicional sea menor al 5 o 10 por ciento.

Siguiendo estos criterios, se seleccionan los cinco primeros componentes principales para el análisis posterior. Esta selección es razonable porque: (1) explican conjuntamente el 72,6 por ciento de la varianza, una proporción sustancial; (2) el quinto componente aporta solo un 9.9% por ciento adicional, un incremento menos pronunciado que el de los anteriores; (3) retener cuatro componentes proporciona un equilibrio entre parsimonia y poder descriptivo, facilitando la visualización e interpretación sin perder información crítica.

ii. Factorial Map Visualization: Círculo de Correlaciones

Para comprender cómo se relacionan las variables originales con los componentes principales y cómo se proyectan en el espacio reducido, se genera el mapa factorial o círculo de correlaciones.





Figura 36: Mapa Factorial



a. Interpretación del Mapa Factorial

El círculo de correlaciones representa cada variable original como un vector en el espacio bidimensional formado por los dos primeros componentes principales (que en conjunto capturan el 48.6 por ciento de la varianza). La posición y orientación de cada flecha comunica información sobre cómo esa variable está correlacionada con cada componente:

Variables en la parte superior derecha del gráfico como RIDAGEYR (edad del participante), DMDHRAGE (edad del referente del hogar), WTMEC2YR (peso mecánico), y WTINT2YR (peso de la entrevista) están fuertemente correlacionadas positivamente con el primer componente principal (eje horizontal). Esto sugiere que el primer componente representa principalmente una dimensión de edad y peso, capturando variabilidad relacionada con la avanzada edad de los participantes y sus pesos muestrales asociados.

Variables en la parte inferior derecha como RIDRETH2 e INDFMIN2 se alinean más con el segundo componente principal (eje vertical), sugiriendo que contribuyen de forma distinta a la estructura de variación, probablemente asociadas a dimensiones étnicas o económicas que no están tan fuertemente vinculadas con la edad.

Variables en la izquierda del gráfico como SDMVSTRA (estratificación de muestreo) y SDMVPSU (unidad primaria de muestreo) están correlacionadas negativamente con el

primer componente, indicando que representan aspectos del diseño muestral que varían de forma opuesta a la edad y el peso.

Variables como INDFMPIR (ratio de pobreza relativa a ingresos) y INDHHIN2 (ingresos familiares categorizados) se proyectan hacia la derecha del gráfico, pero con un patrón diferente, sugiriendo que capturan una dimensión socioeconómica que, aunque relacionada con los componentes principales, tiene su propia estructura de variación.

iii. Interpretation: Significado de los Componentes Principales

a. Componente Principal 1 (30.6% de varianza)

El primer componente está dominado por variables de edad (RIDAGEYR, DMDHRAGE) y pesos muestrales (WTMEC2YR, WTINT2YR). Su interpretación es fundamentalmente una dimensión de edad y ponderación demográfica. Valores altos en este componente corresponden a individuos con mayor edad y mayores pesos muestrales, mientras que valores bajos corresponden a participantes más jóvenes. Este componente captura la estructura demográfica más obvia del dataset: la variabilidad en la edad de la población.

Aunque este componente por sí solo no es sorprendente en un dataset demográfico, su relevancia estadística indica que la edad es el factor más diferenciador de la variabilidad observada en la muestra.

b. Componente Principal 2 (18% de varianza)

El segundo componente tiene una interpretación más compleja, donde intervienen elementos de estratificación muestral (SDMVSTRA, SDMVPSU) y variables económicas. Este componente parece capturar la estructura del diseño muestral combinada con cierta heterogeneidad socioeconómica. No está tan claramente definido como el primero, lo que sugiere que la variabilidad en dimensiones económicas y estructurales del hogar es más dispersa entre múltiples variables que la variabilidad de edad.

c. Componente Principal 3 (13.6% de varianza)

La tercera componente principal está claramente asociada a los pesos muestrales del estudio, especialmente WTMEC2YR y WTINT2YR, que cargan fuertemente y en la misma dirección sobre el eje de la Dimensión 3. Esto indica que CP3 captura principalmente variabilidad ligada al diseño muestral y a la ponderación de los individuos, más que a características sociodemográficas sustantivas.

En contraste, variables como INDFMPIR, INDHHIN2 e INDFMIN2 aparecen muy próximas al origen, lo que sugiere que el componente 3 apenas discrimina por nivel socioeconómico o ingresos. Tampoco se observa una contribución relevante de variables de edad en esta dimensión. Por tanto, este componente no representa un eje interpretativo “social” o “demográfico” fuerte, sino más bien una dimensión técnica, asociada a cómo cada observación contribuye al total de la muestra a través de los pesos. Su inclusión es relevante desde el punto de vista estadístico, pero su interpretación sustantiva es limitada.

d. Componente Principal 4 (10.1% de varianza)

La cuarta componente principal está dominada por las variables de estratificación del muestreo, en particular SDMVPSU (con carga positiva) y SDMVSTRA junto con SEQN (con cargas negativas). Este patrón indica que CP4 recoge variabilidad puramente estructural del diseño de la encuesta, separando unidades primarias de muestreo y estratos.

Las variables demográficas clásicas (edad, ingresos, tamaño del hogar) aparecen muy cercanas al centro del gráfico, lo que confirma que la Dimensión 4 no está relacionada con características individuales, sino con la arquitectura del muestreo.

En consecuencia, la CP4 debe interpretarse como una dimensión metodológica, útil para entender cómo el diseño de la encuesta introduce variabilidad adicional en los datos, pero que no aporta información directa para el análisis de perfiles poblacionales o clustering.

e. Síntesis General

Los cuatro primeros componentes principales, considerados de forma conjunta, permiten comprender la estructura latente del dataset demográfico desde varias dimensiones complementarias.

El primer componente principal está claramente dominado por la edad y concentra la mayor parte de la varianza, reflejando que las diferencias etarias son el eje fundamental que estructura la población. El segundo componente introduce variabilidad asociada al diseño muestral y a ciertos aspectos socioeconómicos, capturando heterogeneidad que no depende únicamente de la edad, sino también de cómo se distribuye la muestra y de diferencias económicas más difusas.

El tercer componente añade una nueva capa interpretativa, relacionada principalmente con ingresos y tamaño del hogar, separando individuos según su posición económica relativa y ciertas características familiares. Finalmente, el cuarto componente principal aporta información adicional vinculada a variables administrativas y de identificación muestral, así como a matices demográficos más finos, que no estaban plenamente explicados por los componentes anteriores.

En conjunto, la retención de estos cuatro componentes permite trabajar con una representación sustancialmente reducida del conjunto original de variables, manteniendo una capacidad descriptiva sólida. Se pasa de un conjunto amplio de variables numéricas a cuatro dimensiones sintéticas que capturan una proporción relevante de la variabilidad total, logrando un equilibrio razonable entre simplificación, interpretabilidad y pérdida mínima de información.

6. Clustering

i. Clustering jerárquico sobre los datos originales

a. Descripción de los datos usados

Para el clustering jerárquico, empleamos una muestra de quinientas observaciones seleccionadas aleatoriamente del módulo demográfico de NHANES 2013-2014, previamente depurado. Este subconjunto es el mismo que se utilizó para el análisis de Modelos Lineales Generalizados.

El proceso de preprocesamiento incluyó la eliminación de columnas con alto porcentaje de datos faltantes y de filas con información incompleta en variables clave, asegurando una muestra consistente y utilizable.

El conjunto final de datos es mixto (numérico y categórico) y combina variables cruciales para capturar la heterogeneidad demográfica y socioeconómica:

- Variables Demográficas: Edad, sexo, estado civil y origen étnico (RIDRETH3).
- Composición del Hogar: Número total de convivientes y distribución por rangos de edad.
- Estatus Socioeconómico: Tramos de ingresos familiares y el ratio de ingreso ajustado por pobreza (INDFMPIR).
- Factores Migratorios/Lingüísticos: País de nacimiento, estatus de ciudadanía, idioma de la entrevista y uso de intérprete.

b. Método de clustering utilizado

Para el proceso de agrupamiento, fue esencial utilizar un enfoque capaz de manejar la naturaleza mixta (heterogénea) de nuestro conjunto de datos. Dado que las variables combinan información numérica (edad, tamaño del hogar, indicadores económicos) con categorías discretas (origen étnico, situación civil, idioma) , se seleccionó la Distancia de Gower. Esta métrica es la opción más adecuada porque evalúa la disimilitud incorporando ambos tipos de variables y normaliza cada dimensión para evitar que las variables numéricas dominen el cálculo. Una vez establecida la matriz de disimilitudes, se exploraron dos estrategias de agregación jerárquica para evaluar la robustez de los clústeres:

Método de Ward (D2): Este método minimiza la variabilidad interna en cada grupo, favoreciendo la formación de clústeres compactos y homogéneos. Se basa en la reducción de la suma de cuadrados dentro de los grupos.


Método de Enlace Completo (Complete Linkage): Evalúa la distancia entre clústeres tomando la distancia máxima entre el par de observaciones más separadas de cada grupo. Tiende a producir estructuras más esféricas y a ser más sensible a los casos extremos.

La comparación entre Ward (que prioriza la cohesión interna y grupos bien definidos) y el Enlace Completo (que enfatiza la separación entre clústeres) permitió obtener una comprensión más matizada de la estructura subyacente de los datos, contribuyendo a la selección final del modelo interpretativo.

c. Dendrogramas

A continuación se muestran los dendrogramas comparativos de los métodos Ward y Complete:

Figura 37: Comparativa de Dendrogramas



En los dendrogramas obtenidos puede apreciarse con claridad cómo cada criterio de agregación imprime una estructura distinta al proceso de fusión. El método de Ward tiende a generar una jerarquía más equilibrada, en la que los clústeres se agrupan de forma progresiva y con saltos relativamente amplios en las alturas superiores del dendrograma. Esta forma de ramificación refleja su énfasis en preservar la homogeneidad interna, de modo que las fusiones finales, las más costosas en términos de variabilidad, se producen a alturas considerablemente mayores. El resultado es una estructura más compacta, caracterizada por grupos relativamente bien definidos y una separación más marcada entre las grandes particiones que surgen en los niveles superiores del árbol.

Por el contrario, el dendrograma correspondiente al enlace completo muestra un patrón más granular, con un número mayor de fusiones tempranas y alturas de corte más reducidas. Este comportamiento se deriva de su criterio basado en la distancia máxima entre elementos de clústeres potencialmente fusionables, lo que tiende a retrasar la unión de conglomerados que contengan puntos especialmente alejados y favorece la aparición de ramas más alargadas y heterogéneas. En conjunto, este método produce una estructura algo más fragmentada en los niveles inferiores y una separación menos abrupta entre los grupos principales.


La comparación visual entre ambos dendrogramas permite apreciar cómo difieren en la forma en que representan la organización interna del conjunto de datos. Mientras Ward

destaca por su capacidad para producir particiones más estables y compactas, el método completo revela una perspectiva más detallada de las disimilitudes locales. El contraste entre ambas soluciones resulta útil para evaluar la robustez de los patrones emergentes y seleccionar el criterio de fusión que mejor se ajuste al objetivo interpretativo del análisis.

d. Número de clústeres escogido

Para estimar el número adecuado de clústeres se recurrió al método del codo, un procedimiento que examina cómo evolucionan las distancias de agregación a medida que se incrementa el número de particiones. La lógica de este enfoque consiste en identificar el punto en el que la reducción de la disimilitud intra-grupo deja de ser significativa, lo que suele manifestarse como un cambio claro en la pendiente de la curva. Para complementar esta inspección visual, se empleó una función diseñada para detectar de forma sistemática el nivel a partir del cual la ganancia en cohesión interna se estabiliza. Esta función evalúa la relación entre los incrementos sucesivos de la distancia acumulada y permite localizar el punto en el que la mejora relativa se reduce de manera notable. Con el fin de reforzar la interpretación, también se representaron los últimos saltos de fusión del dendrograma, lo que facilita apreciar de forma gráfica dónde se forma el “codo” y en qué momento dividir los datos deja de aportar mejoras sustanciales en la estructura de los clústeres.

Figura 38: Comparativa de Diagramas de Codo



Al observar la evolución de las distancias de agregación en ambos gráficos del método del codo se aprecia un patrón coherente entre los dos criterios de fusión, aunque con intensidades distintas. En el caso del método de Ward, la caída inicial es pronunciada entre uno y dos clústeres y vuelve a experimentar un descenso evidente al pasar de dos a tres. A partir de ese punto, el decrecimiento se suaviza de forma notable y las variaciones sucesivas se vuelven mucho más moderadas, lo que indica que la ganancia en cohesión intra-grupo pierde relevancia conforme se incrementa el número de particiones. En términos

visuales, la inflexión más clara aparece alrededor de tres clústeres, donde se percibe un cambio significativo en la pendiente antes de que la curva tienda a estabilizarse.

En el gráfico correspondiente al enlace completo el comportamiento es similar, aunque las distancias se contraen más rápidamente. La reducción más evidente sucede en el salto de uno a dos clústeres y vuelve a producirse una disminución destacable al pasar de dos a tres. A partir de ahí, la curva adopta una forma mucho más suave y sin quiebres abruptos, lo que vuelve a situar el punto de inflexión en torno a tres grupos. En ambos casos, agregar más clústeres después de este punto implica mejoras cada vez menos sustanciales en términos de disimilitud, lo que sugiere que el beneficio marginal de seguir fragmentando la estructura es limitado.

Tomando en conjunto ambas métricas y considerando que el método de Ward suele producir particiones más estables y fáciles de interpretar, la elección más razonable se sitúa en tres clústeres. Este valor captura el punto donde la reducción de la distancia deja de ser claramente significativa y ofrece un equilibrio adecuado entre simplicidad interpretativa y capacidad descriptiva.

A partir de los dendrogramas y del análisis del método del codo, se decidió fijar el corte del árbol jerárquico, siguiendo el criterio de Ward, en tres clústeres. Esta elección se sustenta en la observación de que, hasta ese punto, la reducción en las distancias de agregación es pronunciada y aporta mejoras claras en la compactación interna de los grupos. Sin embargo, a partir del cuarto clúster la curva muestra una clara atenuación en la caída de las distancias, indicando que seguir aumentando el número de particiones apenas introduce ganancias adicionales desde el punto de vista de la estructura del conjunto. La combinación de esta estabilización con la forma más equilibrada del dendrograma de Ward sugiere que tres clusters constituyen una representación adecuada y explicativa de la heterogeneidad demográfica del dataset.

e. Distribución del tamaño de los clústeres

Una vez fijado el valor de k , se procedió a segmentar los datos y a resumir el tamaño resultante de cada grupo. La tabla obtenida muestra con claridad una fuerte asimetría en la composición de los clústeres:

Tabla 15: Resultados

Cluster	Tamaño	Porcentaje
1	359	71.8
2	98	19.6
3	43	8.6

Esta estructura cuantitativa permite reconocer desde el inicio la presencia de un grupo mayoritario y dos subgrupos minoritarios de distinta magnitud, lo que anticipa diferencias relevantes en los patrones sociodemográficos capturados por el algoritmo.

g. Análisis de la estructura de tamaños

La presencia de un clúster mayoritario, que reúne a más de siete de cada diez individuos, sugiere la existencia de un perfil ampliamente extendido en la población estudiada. Este grupo representa un núcleo homogéneo en términos de los atributos considerados, lo que explica su capacidad para agrupar a la mayoría de las observaciones sin que el algoritmo encuentre motivos suficientes para subdividirlo.

El segundo clúster, con casi una quinta parte del total, refleja la existencia de un segmento poblacional con rasgos compartidos pero diferenciado del grupo principal. Su tamaño intermedio indica que no se trata de un subconjunto marginal, sino de un perfil claramente reconocible que aporta una contribución sustancial a la diversidad estructural del dataset.

Por último, el tercer clúster constituye el grupo más reducido, con menos de un diez por ciento de los individuos. Su baja frecuencia sugiere que agrupa características menos comunes pero internamente coherentes, de forma que el algoritmo identifica un patrón distinto que merece ser aislado como unidad independiente dentro de la segmentación.

En conjunto, esta distribución confirma que el corte en tres clústeres captura adecuadamente la estratificación del conjunto de datos: un grupo dominante con rasgos mayoritarios, un clúster secundario de presencia apreciable y un último grupo minoritario que representa un perfil muy específico dentro de la muestra.

ii. Partitional Clustering

a. Descripción de los datos usados


Para el análisis particional se empleó exactamente el mismo subconjunto de datos utilizado en el clustering jerárquico, compuesto por 500 observaciones seleccionadas del conjunto original. Este dataset mantiene las mismas columnas, el mismo preprocesamiento y las mismas transformaciones aplicadas en el análisis anterior. De este modo, se garantiza la comparabilidad directa entre ambos enfoques de agrupamiento, ya que las variables, tanto numéricas como categóricas, conservan idéntico significado y escala, permitiendo evaluar si los patrones detectados por el método jerárquico se sostienen también en un modelo particional.

b. Método de clustering usado

Para la fase particional se adoptó el algoritmo K-Prototypes, una extensión del clásico K-Means diseñada específicamente para manejar conjuntos de datos mixtos. Este método combina dos criterios de disimilitud: la distancia euclidiana para las variables numéricas y una medida basada en coincidencias para las categóricas. Esta dualidad permite que cada atributo contribuya al proceso de agrupamiento de forma adecuada a su naturaleza, evitando que unas variables dominen sobre otras.

Con el objetivo de determinar el número óptimo de clústeres, se generaron particiones para valores de k entre uno y diez. Para cada partición se evaluaron dos indicadores complementarios. Por un lado, la variabilidad explicada, que refleja la proporción de la estructura interna de los datos capturada por el modelo, aumentando a medida que la segmentación consigue grupos más coherentes. Por otro, la inercia intra-clúster, que mide la compacidad de los grupos, disminuyendo cuando las observaciones asignadas a un mismo clúster se parecen más entre sí. Estas métricas permiten interpretar cómo evoluciona la calidad del modelo a medida que se incrementa el número de particiones.

Figura 39: Comparativa de Diagramas de Codo



Los gráficos obtenidos muestran la evolución de ambos indicadores en función del número de clústeres. En el caso de la variabilidad explicada, se observa un incremento rápido y pronunciado entre uno y tres clústeres. A partir de este punto, la curva comienza a estabilizarse, presentando mejoras cada vez más moderadas. Este comportamiento indica

que la ganancia en información estructural se concentra en los primeros valores de k , y que añadir más clústeres aporta beneficios marginales.

La inercia intra-clúster sigue un patrón simétrico: desciende de manera abrupta en los primeros niveles y experimenta una reducción significativa hasta alrededor de tres clústeres. Más allá de este punto, la pendiente se suaviza notablemente, manteniendo un descenso progresivo pero cada vez menos pronunciado. Este cambio en la velocidad de mejora señala nuevamente que la mayor parte de la compresión estructural se alcanza con pocas particiones.

Ambas curvas coinciden en señalar un punto de inflexión claro alrededor de $k = 3$, donde la relación entre mejora estructural y complejidad del modelo empieza a perder equilibrio. Este comportamiento sugiere que tres clústeres constituyen una segmentación razonable también en el contexto del algoritmo K-Prototypes. La convergencia entre este resultado y el obtenido mediante clustering jerárquico refuerza la robustez de la estructura tripartita identificada en el conjunto de datos.

c. Justificación del número óptimo de clústeres

La selección del número de clústeres se fundamentó en la evaluación conjunta de dos métricas complementarias: la variabilidad explicada y la inercia intra-clúster. Ambas curvas muestran un patrón muy similar, lo que permite identificar con claridad el punto a partir del cual los beneficios adicionales de incrementar k se vuelven marginales.

En el gráfico de variabilidad explicada se observa un crecimiento muy pronunciado entre uno y tres clústeres. Este tramo inicial representa la fase en la que el algoritmo está capturando la estructura más relevante de los datos, separando grupos con diferencias sustanciales entre sí. Sin embargo, a partir de $k = 3$ la pendiente cambia de forma evidente: el incremento en variabilidad pasa a ser moderado, indicando que añadir un clúster adicional aporta información más limitada sobre la organización interna del conjunto. Aunque existe cierta mejora al alcanzar $k = 4$, ésta ya no constituye un salto cualitativo, sino un refinamiento secundario.

El gráfico de inercia intra-clúster refuerza esta interpretación. La distancia dentro de los grupos desciende de manera abrupta hasta $k = 3$, mostrando que los clústeres se vuelven significativamente más compactos a medida que se pasa de uno a dos y de dos a tres. A partir de ese punto, la curva pierde pendiente y la reducción de inercia se vuelve sustancialmente menos acusada. Este comportamiento indica que gran parte de la compacidad alcanzable se logra ya con tres clústeres, mientras que incrementos posteriores ofrecen mejoras cada vez más pequeñas.

La coincidencia de ambos indicadores en señalar un cambio de ritmo exactamente en $k = 3$ es clave: se trata del primer punto donde las mejoras dejan de ser drásticas y la relación entre complejidad del modelo y ganancia estructural deja de ser ventajosa.



En conjunto, la evidencia empírica indica que tres clústeres capturan la estructura dominante del dataset sin introducir segmentaciones excesivas. Por este motivo, y en coherencia con los patrones observados, se seleccionó $k = 3$ como la partición final del modelo K-Prototypes y la que se muestra en la representación visual.

d. Representación Visual

Para interpretar de forma intuitiva la estructura obtenida mediante el algoritmo K-Prototypes, se generó una representación bidimensional basada en PCoA (Principal Coordinates Analysis), también conocido como Multidimensional Scaling. Esta técnica proyecta un conjunto de datos multidimensionales en un espacio de dos dimensiones preservando, en la medida de lo posible, las distancias originales entre las observaciones. Dado que el clustering se ha construido a partir de la distancia de Gower, capaz de integrar variables numéricas y categóricas, PCoA constituye un método adecuado para visualizar de forma coherente la geometría del espacio generado por dicha métrica.

El procedimiento parte de la matriz de distancias previamente calculada y obtiene dos ejes principales que capturan la mayor parte de la variabilidad explicada por la configuración espacial. Estos ejes permiten representar cada individuo como un punto en un plano, de manera que las proximidades y separaciones reflejan, de forma aproximada, el grado de similitud entre ellos en el espacio original de características.

Una vez proyectadas las observaciones, se coloreó cada punto según el clúster asignado en la solución final con $k = 3$, el valor seleccionado a partir del análisis del método del codo. Esta representación hace posible observar la formación de regiones densas y áreas de transición, facilitando la evaluación de la coherencia interna de cada grupo.



En la visualización obtenida se aprecia cómo los tres clústeres ocupan zonas parcialmente diferenciadas del plano, aunque con límites difusos debido a la naturaleza compleja y mixta de las variables. El primer clúster se distribuye principalmente hacia la parte izquierda del gráfico, mientras que los otros dos se concentran en zonas más centrales y hacia la derecha. Esta separación visual respalda la segmentación obtenida a partir del algoritmo,

mostrando que los grupos definidos presentan patrones diferenciables cuando se proyectan en un espacio de menor dimensión.

El gráfico del codo incluido junto a la representación visual refuerza la elección de $k = 3$, mostrando que este valor corresponde al primer punto donde la variabilidad explicada presenta una clara desaceleración en su crecimiento. La combinación de ambas figuras la proyección geométrica y el análisis del cod proporciona una validación tanto cuantitativa como visual de la estructura tripartita identificada por el modelo K-Prototypes.

e. Tamaños de los clusters

Una vez completado el proceso de particionamiento mediante K-Prototypes con $k = 3$, se procedió a examinar la distribución cuantitativa de las observaciones dentro de cada clúster. A diferencia de la segmentación jerárquica, donde la distribución era altamente asimétrica, el modelo particional genera una estructura más equilibrada que refleja cómo el algoritmo organiza los datos cuando se deja libertad para reasignar observaciones de forma simultánea.

f. Distribución de tamaños de los clústeres K-Prototypes

La composición resultante de los tres clústeres se muestra en la siguiente tabla:

Tabla 16: Resultados

Cluster	Tamaño	Porcentaje
1	147	29.4
2	106	21.2
3	247	49.4

g. Análisis de la estructura de tamaños en K-Prototypes

La distribución observada presenta un perfil notablemente distinto al obtenido mediante clustering jerárquico. Mientras que el enfoque jerárquico producía un grupo dominante con cerca del setenta por ciento de las observaciones, K-Prototypes genera una estructura más equitativa donde el clúster más grande reúne aproximadamente la mitad de la muestra.

El clúster mayoritario, que concentra casi cincuenta por ciento de los casos, sigue siendo el núcleo más representativo de la población. Sin embargo, a diferencia de la versión jerárquica donde este grupo oscilaba alrededor del setenta por ciento, aquí su preponderancia es menor. Este cambio refleja cómo el algoritmo K-Prototypes, al permitir reasignaciones más flexibles de los centros, tiende a fragmentar grupos muy grandes en particiones más comparables en tamaño.

El segundo clúster, con aproximadamente un tercio de las observaciones, constituye un segmento sustancial de la población. Su tamaño relativo es mayor que en la solución jerárquica, donde representaba cerca del veinte por ciento. Esta diferencia sugiere que K-Prototypes identifica un bloque intermedio de individuos lo suficientemente coherente como para considerarlo un grupo propio, pero que en el dendrograma jerárquico podría haber sido inicialmente fusionado con el grupo mayoritario.

El tercer clúster, con alrededor de un veintiuno por ciento de las observaciones, es el segundo más grande en K-Prototypes, mientras que en el análisis jerárquico ocupaba el espacio más reducido. Este ajuste indica que el método particional percibe una estructura diferente en los datos, donde este grupo minoritario en el enfoque jerárquico adquiere suficiente peso y coherencia para ser tratado como una partición de tamaño intermedio.

h. Comparación entre métodos

La divergencia en los tamaños de los clústeres entre ambos enfoques es informativa sobre la naturaleza de los datos. El clustering jerárquico, basado en agregación progresiva, tiende a producir grupos de tamaños muy desiguales cuando existe un núcleo mayoritario claro. En cambio, K-Prototypes, que realiza una optimización global simultánea, equilibra mejor la distribución buscando particiones de cohesión interna comparable. Ambas soluciones son válidas pero enfatizan aspectos diferentes de la estructura latente: la jerárquica subraya la existencia de un grupo muy predominante, mientras que la particional revela que existen segmentos secundarios con identidad propia relevante.

Esta diferencia no indica un fallo de ninguno de los métodos, sino que pone de manifiesto que los datos contienen capas de estructura: una capa superficial donde existe un grupo muy mayoritario (capturada por el método jerárquico) y capas más sutiles donde ese grupo mayoritario alberga internamente subgrupos con características propias (reveladas por K-Prototypes).

El balance general entre ambas aproximaciones permite una interpretación más robusta de la segmentación. Los tres clústeres identificados existen en ambos análisis, aunque sus límites y proporciones varían según el algoritmo. Este patrón consistente confirma que la

tripartición de $k = 3$ captura una estructura real en los datos y no es un artefacto de un método específico.

iii. Profiling of Clusters

a. Análisis de Distribuciones Condicionales y Tests Estadísticos

Para identificar qué variables contribuyen realmente a la diferenciación entre clústeres, se tomó la asignación al clúster como variable respuesta y se aplicaron pruebas estadísticas apropiadas según la naturaleza de cada variable.

Para las variables numéricas se empleó el test de Kruskal-Wallis, un procedimiento no paramétrico robusto ante desviaciones de normalidad, que es el caso típico en datos demográficos. Para las variables categóricas se aplicó el test de Chi-cuadrado, evaluando diferencias en distribuciones de frecuencias entre grupos.

Los resultados revelan que las variables con mayor poder discriminante ($p\text{-value} < 0.001$) se distribuyen en tres dimensiones principales:

Dimensión Socioeconómica: INDFMPIR (ratio pobreza/ingresos) y DMDEDUC2 (nivel educativo) muestran diferencias muy marcadas entre clústeres, explicando buena parte de la estructura de segmentación.

Dimensión Cultural-Demográfica: DMDBORN4 (país de nacimiento), SIALANG (idioma de la entrevista) y RIDRETH3 (etnia) presentan patrones altamente diferenciadores que reflejan orígenes y contextos culturales distintos.

Composición del Hogar: DMDHHSIZ (tamaño del hogar) distingue significativamente entre grupos, con implicaciones para entender la estructura familiar de cada segmento.

En contraste, variables como RIDAGEYR (edad) y RIAGENDR (género) arrojaron p -valores superiores a 0.05, indicando que no contribuyen significativamente a la separación entre clústeres. Esta ausencia sugiere que la estructura está impulsada principalmente por factores culturales, económicos y demográficos, no por características demográficas básicas.

b. Características Intrínsecas y Diferenciadores entre Clústeres

b.i. Cluster 1: Población General Nativa Angloparlante

Este grupo mayoritario se caracteriza por una identidad marcadamente estadounidense. El 95.8 por ciento de sus miembros nació en territorio norteamericano, estableciendo una base de ciudadanía por nacimiento. La totalidad realiza la entrevista en inglés, indicando dominio lingüístico completo. La composición étnica es predominantemente Blanca No-Hispana. Los niveles de ingresos y educación se sitúan en rangos intermedios, reflejando un perfil de clase media típico. Este clúster encarna el patrón demográfico mayoritario y más integrado de la muestra.

b.ii. Cluster 2: Inmigrantes Cualificados de Origen Asiático

Este grupo se distingue por una combinación única de inmigración exitosa y altos logros educativos. Aunque la mayoría nació en el extranjero, presenta altos índices de ciudadanía. Una abrumadora proporción del 57 por ciento es de origen asiático no-hispano, configurando una identidad étnica claramente identificable. El 48 por ciento alcanza graduación universitaria o superior, comparado con el 26 por ciento global, reflejando concentración en profesionales cualificados. Los ingresos familiares ocupan posiciones altas. El dominio del inglés es predominante, aunque ocasionalmente se recurre a intérpretes. Este perfil representa inmigrantes que han alcanzado integración económica superior.

b.iii. Cluster 3: Inmigrantes Hispanos en Situación Socioeconómica Vulnerable


Este grupo se define por una identidad hispana pronunciada y barreras socioeconómicas significativas. La mayoría nació en el extranjero, principalmente en México. El 90.7 por ciento realiza la entrevista en español, reflejando dominio limitado del inglés y una inserción cultural limitada. El 86 por ciento es de origen mexicano o mexicoamericano. En términos educativos, el 44 por ciento no alcanza completar el noveno grado, concentrándose en las categorías más bajas de formación. El ratio de pobreza promedia 1.58, comparado con 2.41 a nivel global, indicando vulnerabilidad económica generalizada. El tamaño promedio del hogar es sustancialmente mayor, añadiendo presión económica per cápita. Este grupo representa inmigrantes enfrentándose a barreras estructurales de idioma, educación y recursos económicos.

iv. Visualización Gráfica de Perfiles: Boxplots y Gráficos de Distribución

Se han generado gráficos para visualizar cómo cada variable clave se distribuye diferentemente en los tres clústeres, permitiendo una apreciación visual de los patrones estadísticos identificados.


a. Dimensión Socioeconómica

Figura 42: Dimensión Socioeconómica



El ratio de pobreza muestra una gradación clara. El Cluster 2 presenta la mediana más alta, con valores concentrados en la parte superior de la escala, reflejando mayor poder adquisitivo. El Cluster 1 ocupa una posición intermedia con dispersión moderada. El Cluster 3 se sitúa en el extremo inferior, con valores bajos y concentrados, indicando vulnerabilidad económica generalizada. Las cajas sin solapamiento indican diferencias estadísticamente sustanciales.


Figura 43: DMDEDUC2 by Cluster



El nivel educativo muestra patrones categóricos claros. El Cluster 2 concentra masivamente en la categoría superior (5 = graduado universitario o superior), mientras que los otros clústeres se distribuyen más ampliamente. El Cluster 3 muestra predominio en las categorías inferiores (1 y 2), con pocas observaciones en niveles altos. El Cluster 1 se distribuye de forma más equilibrada, sin concentración extrema.


b. Dimensión Cultural y Demográfica

Figura 44: DMDBORN4 by Cluster



El país de nacimiento muestra una división binaria muy clara. El Cluster 1 es casi exclusivamente categoría 1 (nacido en EE.UU.), formando un bloque homogéneo. Los Clusters 2 y 3 se concentran en categoría 2 (nacido fuera de EE.UU.), diferenciándose del grupo nativo pero siendo ambos perfiles inmigrantes.


Figura 45: SIALANG by Cluster



El idioma de la entrevista actúa como discriminador dentro del grupo inmigrante. El Cluster 1 es exclusivamente inglés. El Cluster 2, a pesar de ser inmigrante, utiliza predominantemente inglés, indicando integración lingüística o trasfondo lingüístico no hispano. El Cluster 3 es casi exclusivamente español (categoría 2), reflejando barreras lingüísticas significativas y un contexto cultural hispano dominante.

c. Estructura Familiar

Figura 46: DMDHHSIZ by Cluster



El tamaño del hogar muestra una diferencia notable. El Cluster 3 presenta medianas y dispersión mayores, con hogares típicamente más numerosos. Los Clusters 1 y 2 muestran tamaños más reducidos, con medianas similares pero menor variabilidad. Esta diferencia refuerza el perfil del Cluster 3 como familias más amplias enfrentándose a recursos económicos más limitados.

v. Tests Específicos de Perfilado para Variables Clave

Para confirmar la significancia de las variables socioeconómicas en la segmentación, se calcularon V-tests (medida de contribución a la diferenciación de cada variable en cada clúster).

a. Cluster 2: Confirmación de Estatus Económico Superior

El Cluster 2 exhibe V-tests positivos muy altos para variables económicas:

- **INDFMPIR**: V-test = 2.19, confirming above-average poverty ratio (favorable)
- **INDHHIN2**: V-test = 3.15, indicating notably high family incomes

Estos valores indican que las variables económicas están especialmente sobrerrepresentadas en sus categorías altas, confirmando que el perfil del Cluster 2 es genuinamente de élite económica, no de coincidencia.

b. Cluster 3: Confirmación de Vulnerabilidad Económica

El Cluster 3 exhibe V-tests negativos fuertes para variables económicas:

- **INDFMPIR**: V-test = -3.57, indicating significantly below-average poverty ratios (desfavorable)

Este valor muy negativo subraya que el Cluster 3 se caracteriza consistentemente por ratios de pobreza bajos, confirmando su posición en el espectro económico más vulnerable. La magnitud del V-test refleja qué tan extrema y característica es esta situación para el grupo.

vi. Plantillas de Caracterización de Clústeres

A partir de la integración del análisis estadístico, visual y de pruebas específicas, se sintetizan tres arquetipos demográficos claros:

a. Template 1: "Mainstream Nativo"

Composición: Grupo mayoritario (71.8% de la muestra)

Caracterización Demográfica:

- Nacidos en EE.UU., ciudadanos por nacimiento
- Angloparlantes nativos con dominio completo del idioma
- Predominantemente de etnia Blanca No-Hispana
- Hogares de tamaño promedio (mediana de 3 miembros)

Caracterización Socioeconómica:

- Niveles educativos intermedios, distribuidos ampliamente entre categorías
- Ingresos familiares en rango promedio, sin extremos
- Ratio de pobreza cercano al promedio nacional
- Representan el "ciudadano típico" de la población estudiada

Interpretación: Este grupo encarna el patrón demográfico y socioeconómico mayoritario, caracterizado por ciudadanía plena, integración lingüística total e inserción económica estable pero no excepcional. Su tamaño y características intermedias lo posicionan como el núcleo central de la población.

b. Template 2: "Élite Inmigrante Cualificada (Asiática)"

Composición: Grupo intermedio (19.6% de la muestra)

Caracterización Demográfica:

- Nacidos en el extranjero, pero con altos índices de ciudadanía completada
- Predominantemente de origen asiático no-hispano (57%)
- Uso principal del inglés en entrevistas, con ocasional recurso a intérpretes
- Hogares de tamaño similar al Cluster 1

Caracterización Socioeconómica:

- Altamente cualificados: 48% con graduación universitaria o superior (vs. 26% global)
- Ingresos familiares altos, concentrados en tramos superiores
- Ratio de pobreza elevado, indicando mayor poder adquisitivo (V-test = 2.19)
- Perfil profesional y de clase alta claramente identificable

Interpretación: Este grupo representa una historia de inmigración exitosa caracterizada por capital educativo y ocupacional elevado. A pesar de nacer fuera del país, han alcanzado una integración económica superior, configurando una élite profesional dentro de la muestra. Su origen predominantemente asiático sugiere patrones de inmigración selectiva hacia profesiones especializadas.

c. Template 3: "Inmigrantes Hispanos Vulnerables"

Composición: Grupo minoritario (8.6% de la muestra)

Caracterización Demográfica:

- Nacidos principalmente en el extranjero, predominantemente México
- Hispanohablantes: 90.7% realiza entrevista en español
- De origen mexicano-americano (86%)
- Hogares significativamente más numerosos (mediana superior)

Caracterización Socioeconómica:

- Niveles educativos muy bajos: 44% sin completar noveno grado
- Ingresos familiares en tramos inferiores, concentrados en categorías bajas
- Ratio de pobreza bajo (media 1.58 vs. 2.41 global), indicando clara vulnerabilidad económica (V-test = -3.57)
- Presión económica adicional por tamaño familiar mayor

Interpretación: Este grupo representa migrantes enfrentándose a barreras estructurales significativas de idioma, educación y recursos económicos. Su pequeño tamaño relativo (8.6%) contrasta con su alta homogeneidad interna, sugiriendo un perfil muy específico y diferenciado. Los hogares más numerosos con menores ingresos per cápita indican situaciones de presión económica compuesta. A diferencia del Cluster 2, la inmigración aquí

no ha resultado en movilidad socioeconómica, sino que se mantienen en posiciones de vulnerabilidad.

vii. Conclusión General del Profiling

El profiling ha revelado una segmentación poblacional coherente y multidimensional. Los tres clústeres no son artefactos estadísticos sino arquetipos demográficos robustos, cada uno definido por combinaciones específicas de origen, idioma, educación e ingresos. Las pruebas estadísticas confirman que estas diferencias no son resultado de variación aleatoria sino de estructuras reales en los datos. La integración de tests numéricos, visualización gráfica y síntesis cualitativa proporciona una comprensión completa de la diversidad demográfica capturada en el análisis de clustering.

7. Discusión y Conclusiones

El objetivo central de este proyecto era integrar evidencia microeconómica (NHANES) y macroeconómica (CPS ASEC) para caracterizar la vulnerabilidad socioeconómica en EE. UU., sus factores predictores a nivel individual, y cómo esta se manifiesta en diferentes grupos demográficos durante las crisis históricas. Los resultados de los análisis de Regresión Lineal Generalizada (GLMz), Series Temporales (TS), Análisis de Componentes Principales (PCA) y Clustering proporcionan una imagen robusta y coherente de la desigualdad y la resiliencia en la población.

i. Determinantes Individuales de la Vulnerabilidad (GLMz)

El modelo GLMz (familia Gamma, link log) identificó los factores más significativos asociados con el ratio de ingresos/pobreza (INDFMPIR):

- Factores Protectores Clave: La educación es el determinante más potente. El estado civil casado también actúa como un protector sólido frente a la pobreza relativa.
- Factores de Riesgo Estructurales: La presencia de hijos pequeños (menores de 5 años) es el factor con el mayor impacto negativo, reduciendo el ingreso relativo en casi un 20%. Los hogares con jefatura femenina también presentan ingresos significativamente menores (-5.5%).
- Interacción y Barreras: Se confirmó que el beneficio de la educación se atenúa notablemente para aquellos cuya entrevista se realiza en español, lo que subraya la existencia de barreras lingüísticas que limitan la conversión del capital humano en capital económico.

ii. Estructura Poblacional de la Desigualdad (Clustering y PCA)

El análisis de clustering (Distancia de Gower, validado por los métodos jerárquico y particional) reveló una estructura poblacional tripartita robusta:

- Cluster 1: Mainstream Nativo (Mayoría): Ciudadanos nacidos en EE. UU. y angloparlantes, con ingresos y educación en rango promedio. Constituyen el núcleo estable de la población.
- Cluster 2: Élite Inmigrante Cualificada (Asiática): Inmigrantes con alto capital educativo e ingresos elevados (\$V-test=2.19\$ favorable para INDFMPIR). Representan una migración exitosa y profesional.
- Cluster 3: Inmigrantes Hispanos Vulnerables (Minoría): Inmigrantes predominantemente de origen mexicano, con fuertes barreras lingüísticas y bajos niveles educativos. Su ratio de pobreza es significativamente bajo (\$V-test=-3.57\$ desfavorable), confirmando su posición de vulnerabilidad extrema.

iii. Vulnerabilidad Histórica ante Crisis (Time Series)

El análisis de Series Temporales (modelo ARIMA(2,1,0)) sobre la tasa de pobreza macroeconómica por grupo demostró una vulnerabilidad diferencial en el tiempo:

- Vulnerabilidad Extrema en Crisis Tradicionales: La población hispana fue consistentemente el grupo más golpeado en las recesiones de Reagan (+8.0 pp de aumento en la tasa de pobreza) y la Gran Recesión (+5.2 pp).
- Mitigación por Política Fiscal: Los incrementos de pobreza durante la crisis de COVID-19 fueron dramáticamente menores que en crisis previas, lo que sugiere que las intervenciones fiscales y de apoyo a la renta implementadas pueden mitigar eficazmente los efectos inmediatos de un shock económico.
- Vulnerabilidad Contextual: La población asiática mostró mayor sensibilidad en la Crisis DotCom y COVID-19, lo que evidencia que el "grupo más vulnerable" depende del tipo de shock económico.

iv. Integración y Síntesis

La integración de los resultados es concluyente:

1. Los factores de riesgo individuales identificados en el GLMz (baja educación, barrera lingüística, hijos dependientes) se ven reflejados de forma extrema y concentrada en el Cluster 3 (Inmigrantes Hispanos Vulnerables).
2. La vulnerabilidad macroeconómica mostrada por los Hispanos en el análisis de Series Temporales es la consecuencia directa de las desventajas estructurales (idioma, educación) que definen a este segmento poblacional.

El proyecto concluye que la vulnerabilidad socioeconómica es un fenómeno multidimensional impulsado por barreras estructurales, migratorias y educativas que actúan de forma compuesta, concentrando el riesgo en grupos específicos y marginados del mainstream socioeconómico.

8. Comparativa Gantt

Figura 47: Diagrama Gantt inicial





Figura 48: Diagrama Gantt final



i. Conclusión de las diferencias entre los diagramas Gantt

Al comparar cómo planeamos el proyecto (el 'Expected') versus cómo lo ejecutamos realmente (el 'Actual'), notamos que tuvimos que ser muy flexibles para manejar algunos retrasos iniciales. La primera fase, el *Data Preprocessing* (Tarea 1), salió según lo planeado, pero al pasar a las tareas más técnicas, las cosas se movieron una semana: el *Initial Statistical Analysis* (Tarea 2) y el *GLM Modeling* (Tarea 3) debían arrancar el 5 y 12 de octubre, pero lo hicieron el 12 y 19 de octubre.

Esto metió presión automáticamente al resto del calendario. Afortunadamente, las fases de modelización avanzada como *Time Series Analysis* (Tarea 4), *PCA* (Tarea 7) y *Clustering* (Tarea 8) se mantuvieron en los tiempos que habíamos estimado, lo cual habla muy bien de la eficiencia del equipo en la parte técnica y de realizar el código. El verdadero impacto del retraso se sintió en la recta final: la *Report & Script Compilation* (Tarea 11) se llevó la peor parte.

Habíamos reservado un margen cómodo de tres semanas (del 23/11 al 7/12) para que el informe fuera de máxima calidad, pero tuvimos que comprimirla a dos semanas (del 30/11 al 7/12).

Esta reducción de tiempo fue clave para asegurar que la *Presentation Preparation* (Tarea 12) pudiera empezar justo a tiempo, la semana del 14/12, cumpliendo así con el plazo de entrega final que habíamos prometido.

En resumen, el equipo compensó el tiempo perdido al inicio acelerando significativamente la fase de documentación, lo que nos permitió entregar el proyecto en la fecha final original.