

Pre-project: Análisis del Gap de Pobreza en EEUU

Modelització Estadística

Jordi Cortés, Dante Conti



Octubre 2025

Grupo:

Nicolas Rosales, Robert Ostrozhinskiy, Alex Latorre,
Javier Aranda

Universitat Politècnica de Catalunya

1. Introducción	3
i. Problema	3
ii. Data	3
a. Fuente	3
b. Cómo conseguimos los datos	3
c. Descripción del dataset	4
d. Estructura del Dataset	6
e. Pre-procesamiento	8
iii. Work Plan	9
a. Equipo e Información del Proyecto	9
b. Assignment Chart	9
c. Gantt Diagram	10
d. Prevención de Riesgos	10
iv. Objetivos	11
2. Análisis Estadístico Inicial	12
i. Pre-procesamiento	12
a. Carga Inicial y Exploración	12
b. Identificación de la Variable Objetivo	12
c. Criterios de Selección de Características	12
c.1 Criterio de Datos Faltantes	12
c.2 Criterio de Correlación con la Variable Objetivo	12
c.3 Excepciones Basadas en Relevancia Teórica	13
d. Resultado de la Selección	13
e. Homogeneización de Valores Faltantes	13
f. Eliminación de Filas Incompletas	14
g. Conversión a Factores	14
h. Eliminación NA's de la Variable Objetivo	14
i. Dataset Final	14
ii. Univariate Descriptive Statistics	15
iii. Bivariate Descriptive Analysis	17
a. Interacciones de las Variables	21
iv. Conclusiones	23
a. Estructura de Variables y Sesgo Univariado	23
b. Relaciones Bivariadas y Detección de Features del modelo binario	24
c. Interacciones de Features	24
d. Final Thoughts	24
3. Generalized Linear Models (GLMz)	25
i. Model fitting	25
a. Modelo 1 (familia gaussiana, link identidad)	25
b. Modelo 2 (familia gaussiana, link log)	25
b. Modelo 3 (familia Gamma, link log)	26
ii. Model Validation (deviance statistic)	26
a. Validación Numérica (Modelo 1)	26

b. Validación Numérica (Modelo 2)	26
c. Validación Numérica (Modelo 3)	26
d. Validación Gráfica (Modelo 1)	27
e. Validación Gráfica (Modelo 2)	27
f. Validación Gráfica (Modelo 3)	28
g. ANOVAS	29
iii. Model Interpretation	30
1. Género (RIAGENDR)	30
2. Edad (RIDAGEYR)	30
3. Etnicidad (RIDRETH3)	31
4. Nivel Educativo (DMDEDUC2)	31
5. Idioma e Intérprete (SIALANG, SIAINTRP)	31
6. Tamaño y Composición del Hogar	32
7. Género y Edad del Cabeza de Hogar	33
8. Educación del Cabeza de Hogar (DMDHREDU)	33
9. Estado Civil del Cabeza de Familia (DMDHRMAR)	34
10. Interacción Educación × Idioma (DMDEDUC2 × SIALANG)	34
11. Ponderación (WTINT2YR)	35
12. Conclusiones Generales	35
iv. Presentación Modelo Binario	35
v. Binary Model fitting	36
a. Modelo 1 (balanced data)	36
b. Modelo 2 (unbalanced data)	36
vi. Binary Model Validation	36
a. AUC - ROC validation	36
b. Validación Gráfica	37
c. Simplificación modelo binario	38
d. Resumen	39
vii. Interpretación Modelo Binario	40
1. Género (RIAGENDR)	40
2. Edad (RIDAGEYR)	40
3. Etnicidad (RIDRETH3)	41
4. Ciudadanía (DMDCITZN)	41
5. Nivel educativo (DMDEDUC2)	41
6. Idioma de la entrevista (SIALANG)	42
7. Conclusión general	42
4. Time Series (TS)	43
i. Selección de Dataset	43
ii. Preguntas a Investigar	45
iii. Modelo Series Temporales	46
a. Transformación Logarítmica	46
b. Diferenciación para Estacionariedad	47
c. Identificación del Modelo	47
d. Diagnóstico del Modelo	48

iv. Resultados y Validación	49
a. Recesión de Reagan (1980-1983)	50
b. Crisis DotCom (2001-2003)	50
c. Gran Recesión (2008-2010)	50
d. COVID-19 (2020-2021)	50
v. Conclusiones	51

1. Introducción

i. Problema

Este proyecto busca entender la vulnerabilidad socioeconómica en EEUU a dos niveles:

- MICRO (NHANES): Identificar qué características individuales (salud, educación, demografía) predicen vulnerabilidad económica medida por INDFMPIR (ratio ingreso/pobreza).
- MACRO (CPS ASEC): Cuantificar cómo estas vulnerabilidades se manifiestan durante crisis económicas, identificando qué grupos demográficos experimentan los mayores aumentos en pobreza.

La integración de ambas perspectivas permite:

- 1) Caracterizar factores de riesgo a nivel individual (GLM)
- 2) Observar cómo estos se traducen en impactos por grupo durante recesiones (Time Series)

ii. Data

a. Fuente

El conjunto de datos proviene de la Encuesta Nacional de Examen de Salud y Nutrición (NHANES).

b. Cómo conseguimos los datos

Primero buscamos conjuntos de datos en el sitio web oficial de NHANES del CDC para asegurarnos de que cumplieran con los requisitos del proyecto.

Como los archivos originales estaban en formato XPT y resultaba difícil transformarlos, descargamos una versión desde Kaggle, que ofrece los mismos datos en un formato CSV más accesible.

c. Descripción del dataset

El NHANES (National Health and Nutrition Examination Survey) es un programa continuo del Centro Nacional de Estadísticas de Salud (NCHS), dependiente de los Centros para el Control y la Prevención de Enfermedades (CDC) de Estados Unidos.

Su propósito es evaluar el estado de salud, la dieta y la nutrición de la población civil no institucionalizada de EE.UU., recopilando datos representativos a nivel nacional que combinan entrevistas, cuestionarios, exámenes físicos y pruebas de laboratorio.

El NHANES se compone de varias secciones o módulos de datos, organizadas por temas o tipos de información.

Entre las principales partes se incluyen:

a) Datos demográficos

Incluyen información básica sobre los participantes:

- Edad, sexo, raza/etnicidad
- Nivel educativo y situación económica
- Tamaño del hogar y lugar de residencia

b) Datos dietéticos (Dietary Data)

Evalúan los hábitos alimenticios de los participantes mediante:

- Recordatorios de consumo de alimentos de 24 horas
- Cuestionarios de frecuencia alimentaria
- Análisis de nutrientes y consumo energético

c) Exámenes de salud (Examination Data)

Son mediciones físicas realizadas por personal médico en unidades móviles:

- Peso, altura, índice de masa corporal (IMC)
- Presión arterial, densidad ósea, fuerza muscular
- Exámenes dentales, visuales y auditivos
- Evaluaciones médicas especializadas (por ejemplo, pulmonares o cardiovasculares)

d) Datos de laboratorio (Laboratory Data)

Incluyen resultados de análisis de sangre, orina y otros fluidos corporales:

- Niveles de glucosa, colesterol, hierro, vitaminas y minerales
- Marcadores de enfermedades infecciosas
- Detección de exposición a contaminantes ambientales (como plomo o mercurio)

En nuestro caso, decidimos investigar los datos demográficos. En la siguiente tabla, se puede apreciar que definición tiene cada variable del dataset.

Tabla 01: Descripción de las Variables del Dataset

AIALANGA	Idioma del cuestionario ACASI (MEC)
DMDBORN4	País de nacimiento
DMDCITZN	Ciudadanía estadounidense
DMDDEDUC2	Nivel educativo más alto
DMDDEDUC3	Nivel educativo más alto
DMDFMSIZ	Tamaño de la familia
DMDHHSIZ	Tamaño del hogar
DMDHHSZA	Niños ≤ 5 en el hogar
DMDHHSZB	Niños 6–17 en el hogar
DMDHHSZE	Adultos ≥ 60 en el hogar
DMDHRAGE	Edad del referente del hogar
DMDHRBR4	País de nacimiento del referente
DMDHREDU	Educación del referente del hogar
DMDHRGND	Sexo del referente del hogar
DMDHRMAR	Estado civil del referente
DMDHSEDU	Educación del cónyuge del referente
DMDMARTL	Estado civil del participante
DMDYRSUS	Años en EE. UU.
DMQADFC	Servicio en misiones/zonas de conflicto
DMQMILIZ	Servicio activo en fuerzas armadas (EE. UU.)
FIAINTRP	Intérprete en entrevista familiar
FIALANG	Idioma de la entrevista familiar
FIAPROXY	Entrevista familiar con proxy
INDFMIN2	Ingreso familiar total (rango)
INDFMPIR	Índice ingreso/pobreza (PIR)
INDHHIN2	Ingreso del hogar total (rango)
MIAINTRP	Intérprete en entrevista CAPI MEC
MIALANG	Idioma de la entrevista CAPI MEC

MIAPROXY	Entrevista CAPI MEC con proxy
RIAGENDR	Sexo del participante
RIDAGEMN	Edad en meses (selección)
RIDAGEYR	Edad en años (selección)
RIDEXAGM	Edad en meses (examen)
RIDEXMON	Periodo semestral del examen
RIDEXPRG	Embarazo (mujeres 20–44) en MEC
RIDRETH1	Raza/origen hispano (recod.)
RIDRETH3	Raza/origen hispano (con asiático no hispano)
RIDSTATR	Estado de entrevista/examen
SDDSRVYR	Ciclo de liberación de datos
SDMVPSU	PSU enmascarada para varianza
SDMVSTRA	Estrato enmascarado para varianza
SEQN	Número de secuencia del encuestado
SIAINTRP	Intérprete en entrevista de SP
SIALANG	Idioma de la entrevista de SP
SIAPROXY	Entrevista de SP con proxy
WTINT2YR	Peso de entrevista (2 años)
WTMEC2YR	Peso de examen MEC (2 años)

d. Estructura del Dataset

Tabla 02: Estructura del Dataset

Numero de filas	10175
Numero de variables	47
Variables Numericas	11
Variables Numericas	6
Variables Categoricas	24
Otros	4

Tabla 03: % de Valores Faltantes del Dataset

Variable	Missings	Missing %
RIDAGEMN	9502	93.39
DMQADFC	9632	94.66
RIDEXAGM	5962	58.59
RIDEXPRG	8866	87.14
DMDYRSUS	8267	81.25
DMDEDUC3	7372	72.45
DMDEDUC2	4406	43.30
DMDMARTL	4406	43.30
DMQMILIZ	3914	38.47
AIALANGA	3858	37.92
MIALANG	2864	28.15
MIAPROXY	2863	28.14
MIAINTRP	2862	28.13
DMDHSEDU	4833	47.50
INDFMPIR	785	7.71
RIDEXMON	362	3.56
DMDHRBR4	297	2.92
DMDHREDU	294	2.89
FIALANG	121	1.19
FIAPROXY	121	1.19
FIAINTRP	121	1.19
INDHHIN2	133	1.31
INDFMIN2	123	1.21
DMDHRMAR	123	1.21
SIAPROXY	1	0.01
DMDCITZN	4	0.04

El porcentaje de datos faltantes en total es de aproximadamente 17.16 %.

e. Pre-procesamiento

Nuestra idea de pre-procesamiento sigue tres filtros:

Filtro 1 - Datos faltantes: Eliminar columnas con >50% de missing values, evaluando caso por caso aquellas entre 40-50% según relevancia teórica. Tras homogeneizar missing values, eliminar filas con valores 0 en variables críticas, asegurando observaciones completas en predictores clave.

Filtro 2 - Correlación con objetivo: Calcular correlación absoluta con INDFMPIR, estableciendo un mínimo. Variables con correlación inferior se descartan.

Filtro 3 - Relevancia conceptual: Mantener variables demográficas fundamentales (edad, género, etnicidad, ciudadanía, educación) incluso con correlaciones moderadas, por su importancia teórica en el estudio de vulnerabilidad socioeconómica.

Dataset Final

El resultado del pre-procesamiento acabará siendo un conjunto de datos optimizado que cumple:

- 20 variables con relevancia correlacional y teórica
- Datos completos en todas las variables de modelado
- Tipificación correcta (factores vs. numéricas)
- Variable objetivo completamente observada
- Tamaño muestral robusto (n=5,121)

Este dataset limpio constituye la base para todo el análisis estadístico a llevar a cabo.

iii. Work Plan

a. Equipo e Información del Proyecto

Miembros:

- Alex (Project Manager)

Responsable de la coordinación general y asegurar que se cumplan los plazos.

- Nicolas

Gestión de datos y el modelado estadístico.

- Robert

Interpretación del análisis y la visualización.

- Javier

redacción del informe y la presentación.

b. Assignment Chart

Tabla 03: Roles de los Miembros del Equipo


Participant	Alex	Nicolas	Robert	Javier
T1	X	X	X	X
T2	X	X	X	
T3	X	X	X	X
T4		X	X	X
T5	X	X		X
T6	X		X	X
T7	X	X	X	
T8		X	X	X
T9	X		X	X
T10	X	X	X	X
T11	X	X		X
T12	X		X	X

Tabla 04: Distribución de Tasks

Task	Task ID
Data Preprocessing	T1
Initial Statistical Analysis	T2
GLM Modeling	T3
Time Series Analysis	T4
D4 Report & Script Compilation	T5
D4 Presentation Preparation	T6
PCA Analysis	T7
Clustering	T8
Profiling of Clusters	T9
Discussion, Conclusions & Plan Review	T10
D5 Report & Script Compilation	T11
D5 Presentation Preparation	T12

c. Gantt Diagram

Figura 01: Diagrama Gantt de organización



d. Prevención de Riesgos

Tabla 05: Riesgos y cómo solventarlos

Riesgo	How to Prevent	How to manage
Falta de datos temporales	Verificar las variables temporales desde el inicio y asegurar que el preprocesamiento cumpla con los supuestos de modelos GLM o de series temporales (TS).	Si el conjunto de datos no contiene información temporal adecuada, buscar un conjunto de datos alternativo que sí la incluya.
Dataset con demasiados missings	Inspeccionar los datos faltantes al comienzo del preprocesamiento: calcular el porcentaje y los patrones de ausencia. Definir una estrategia de imputación antes del modelado. Aplicar métodos de imputación múltiple cuando sea posible. Eliminar variables o filas solo si existe una justificación sólida.	Usar modelos robustos que toleren datos incompletos. Documentar claramente las limitaciones en el informe final.
Rendimiento insuficiente de los modelos	Elegir el enlace (link) y la familia de distribución adecuados según la variable respuesta. Verificar escalado de variables y colinealidad antes del ajuste del modelo.	Probar enlaces o familias alternativas, simplificar el modelo o transformar variables si es necesario. Consultar con el profesor o tutor en caso de persistir los problemas de ajuste.

Indisponibilidad de un miembro del equipo	Asignar al menos dos integrantes por tarea para evitar bloqueos.	Si un miembro no está disponible, reasignar el trabajo pendiente equilibrando los esfuerzos del resto del equipo. El líder del equipo asume las tareas prioritarias para mantener el cronograma y evitar retrasos en el camino crítico.
Dificultades técnicas	Utilizar control de versiones (GitHub) y documentar todas las dependencias y versiones en un archivo requirements.txt.	Crear un entorno virtual limpio y reinstalar las dependencias desde cero. Actualizar o degradar paquetes hasta lograr un entorno estable y funcional.

iv. Objetivos

El objetivo principal es integrar evidencia micro (NHANES) y macro (CPS ASEC) para caracterizar factores asociados a vulnerabilidad y su evolución en el tiempo. Además, tenemos como objetivos adicionales:

- Preprocesar y describir NHANES, justificando decisiones sobre missing, outliers y transformaciones.
- Ajustar y validar dos modelos GLMz (respuesta numérica y binaria) adecuados a la distribución de las variables.
- Construir un modelo ARIMA anual sobre la serie agregada de pobreza (All Races), siguiendo el flujo de clase (transformación logarítmica, $d=1$, identificación AR, validación de residuos, pronóstico).
- Cuantificar, por grupo demográfico, los aumentos de pobreza (pp) en cuatro crisis: Reagan (1980-1983), DotCom (2001-2003), Gran Recesión (2008-2010) y COVID-19 (2020-2021), comparando picos con un baseline de 3 años previos.
- Entregar un informe reproducible con figuras/tablas que respondan: qué grupos fueron más golpeados en cada recesión y con qué magnitud.

2. Análisis Estadístico Inicial

i. Pre-procesamiento

a. Carga Inicial y Exploración

El dataset original contiene 47 columnas con información diversa sobre características individuales, familiares y socioeconómicas de los participantes. La exploración inicial reveló una estructura compleja con múltiples tipos de datos, valores faltantes codificados de diferentes formas, y un número de variables demasiado grande para un modelado eficiente.

b. Identificación de la Variable Objetivo

Para guiar el proceso de selección de características, identificamos INDFMPIR (ratio de ingresos respecto al umbral de pobreza) como la variable objetivo principal del análisis de regresión continua. Esta variable representa una medida de estatus socioeconómico y permite evaluar cómo las características demográficas, educativas y familiares se relacionan con la situación económica de los individuos. Como el número de columnas es elevado, decidimos primero escoger la variable que usaremos para el modelo de regresión, para de esta manera poder añadir criterios de eliminación de columnas dependiendo de la correlación con esta variable objetivo.

c. Criterios de Selección de Características

Dada la alta dimensionalidad del dataset original (47 columnas), necesitábamos reducir el número de variables de manera sistemática. Aplicamos los siguientes criterios:

c.1 Criterio de Datos Faltantes

Eliminamos todas las columnas con más del 50% de valores faltantes, ya que estas variables no proporcionaban suficiente información para un análisis robusto. Además, evaluamos con cuidado las columnas con entre 40% y 50% de datos faltantes, descartándolas en la mayoría de los casos salvo cuando mostraban relevancia teórica o relación clara con la variable objetivo.

c.2 Criterio de Correlación con la Variable Objetivo

Para las columnas que pasaban el filtro de datos faltantes, calculamos la correlación absoluta (Eta para variables categóricas, Pearson para continuas) con INDFMPIR. Establecimos un umbral mínimo de correlación absoluta de 0.15 para considerar que una variable tiene relevancia predictiva suficiente. Las variables con correlaciones menores a este umbral fueron descartadas por considerarse de débil asociación con el resultado de interés. También eliminamos columnas con información redundante como por ejemplo variables como WTMEC2YR, que nos proporcionan información similar a WTINT2YR. Hemos intentado mantener al menos una columna de cada que proporcione información única e independiente para evitar colinealidad entre variables a no ser que la información no fuera relevante.

c.3 Excepciones Basadas en Relevancia Teórica

A pesar de los criterios anteriores, mantuvimos algunas variables con correlaciones moderadas o datos faltantes intermedios cuando su relevancia era clara. Por ejemplo, DMQMILIZ (participación en servicio militar) fue retenida tanto para el análisis de regresión como para desarrollar un modelo binario independiente, aunque su correlación con INDFMPIR fuera moderada, debido a su importancia sociológica, lo mismo con variables como por ejemplo el lugar de nacimiento, la edad, el género, etc.

d. Resultado de la Selección

Del total de 47 columnas originales, seleccionamos 20 variables para el análisis posterior:

- Variables demográficas: RIAGENDR (género), RIDAGEYR (edad del participante), RIDRETH3 (etnicidad)
- Variables de lugar de nacimiento y ciudadanía: DMDBORN4, DMDCITZN
- Variables educativas: DMDDEDUC2 (educación del participante), DMDHREDU (educación del cabeza de hogar)
- Variables lingüísticas: SIALANG (idioma de entrevista), SIAINTRP (uso de intérprete)
- Variables de estructura y composición del hogar: DMDFMSIZ (tamaño de familia), DMDHHSZA (niños <5 años), DMDHHSZB (niños 6-17 años), DMDHHSZE (adultos ≥60 años), DMDHRGND (género del cabeza), DMDHRAGE (edad del cabeza), DMDHRBR4 (número de hermanos del cabeza), DMDHRMAR (estado civil del cabeza)
- Variables de ponderación: WTINT2YR (pesos de la encuesta)
- Variable binaria de interés: DMQMILIZ (participación en servicio militar)
- Variable objetivo: **INDFMPIR**

e. Homogeneización de Valores Faltantes

Una vez seleccionadas las columnas relevantes, nos encontramos con un problema común en encuestas: los valores faltantes estaban codificados de múltiples formas. Específicamente:

- Los valores 7 o 77 representaban "negación a responder" (refused)
- Los valores 9 o 99 representaban "no sabe" (don't know)
- Los valores NA representaban datos ausentes en el formato de R

Para simplificar la representación y mantener consistencia en el tratamiento de valores faltantes, se agruparon todas estas categorías bajo un único código: **0**. Esta codificación permitiría identificar fácilmente las filas con datos faltantes en variables críticas.

f. Eliminación de Filas Incompletas

Tras homogeneizar de códigos de valores faltantes (ahora representados como 0), eliminamos todas las filas que contenían al menos un valor 0 en las columnas críticas: DMDBORN4, DMDCITZN, DMDEDUC2, DMDHRBR4, DMDHREDU, DMQMILIZ y DMDHRMAR.

Esta estrategia asegura que el análisis subsecuente se realiza sobre un dataset con observaciones completas en las variables más importantes para el modelado. Aunque este proceso resulta en una reducción del tamaño muestral, garantiza la calidad e integridad de los datos para fases posteriores.

g. Conversión a Factores

Una vez completado el proceso de limpieza, identificamos todas las variables categóricas y las convertimos explícitamente al tipo factor en R. Esto es fundamental para que el software las trate correctamente durante el modelado, evitando interpretaciones incorrectas como variables numéricas continuas.

Las variables categóricas incluían idiomas, características demográficas, estados civiles, niveles educativos, indicadores de empleo y otras medidas cualitativas.

h. Eliminación NA's de la Variable Objetivo

La variable INDFMPIR presentaba 418 valores faltantes (7.55% del dataset original de 5539 filas). En lugar de imputar estos valores con la mediana, decidimos eliminar estas observaciones directamente. Esta decisión se justifica porque: imputar la variable objetivo introduce sesgo artificial en el modelo, ya que "fabrica" datos que no fueron observados, afectando la calibración de los coeficientes. Además un 7.55% de pérdida es aceptable y deja un tamaño de muestra robusto de 5121 observaciones. Finalmente eliminar filas incompletas es la práctica estándar en regresión cuando el porcentaje de missing es moderado, garantizando integridad estadística. El resultado es un dataset final completamente observado en la variable objetivo, listo para el modelado.

i. Dataset Final

El proceso completo de pre-procesamiento resulta en un dataset optimizado, con:

- **20 variables seleccionadas** basadas en relevancia correlacional y teórica
- **Datos completos** en todas las variables críticas para el modelado
- **Homogeneidad** en la representación de valores faltantes
- **Tipificación correcta** de variables (factores vs. numéricas)
- **Imputación robusta** de la variable objetivo


Este dataset limpio y estructurado constituyó la base para todos los análisis posteriores, incluyendo estadísticas descriptivas, construcción de modelos predictivos y validación estadística.

ii. Univariate Descriptive Statistics

Después del preprocesamiento, hacemos un breve análisis descriptivo univariable a través de la función de summary, y las gráficas de distribución de las variables preprocesadas y las procesadas y seleccionadas para los modelos que llevaremos a cabo.

El análisis univariado descriptivo básico de las variables numéricas retenidas tras el preprocesamiento revela una diversidad de distribuciones que informan sobre la estructura de los datos seleccionados (NHANES).

Figura 02: Distribución de RIDAGEYR



Variables como RIDAGEYR (edad en años) exhiben distribuciones aproximadamente simétricas con baja asimetría (skewness = 0.44), facilitando el uso de técnicas paramétricas sin transformaciones adicionales.

Figura 03: Distribución de WTINT2YR





Figura 04: Distribución de INDFMPIR



En contraste, variables como WTINT2YR (peso de entrevista) e INDFMPIR (ratio de pobreza) presentan asimetrías positivas pronunciadas ($\text{skewness} > 1$), con colas largas hacia la derecha, lo que indica que podrían beneficiarse de transformaciones logarítmicas o del uso de estimadores robustos para reducir la influencia de valores extremos en el modelo.

Figura 05: Distribución de DMDFMSIZ






Figura 06: Distribución de DMDHRAGE



Otras variables, como DMDFMSIZ (tamaño de la familia) y DMDHRAGE (edad del cabeza de familia), presentan distribuciones discretas o moderadamente sesgadas, reflejando patrones demográficos típicos.

Figura 07: Distribución de RIDSTATR



Variables binarias o categóricas numéricas, como RIDSTATR (estado de entrevista/examen), tienen baja variabilidad, con valores concentrados en categorías dominantes. En conjunto, estas características resaltan la necesidad de evaluar la normalidad y el sesgo para detectar posibles distorsiones en las relaciones entre variables, priorizando aquellas con distribuciones más estables que faciliten una modelización lineal fiable.

iii. Bivariate Descriptive Analysis

Para ver la relación entre nuestras variables decidimos escoger la variable binaria objetivo que usaremos posteriormente para nuestro modelo binario, de esta manera podemos observar la relación entre nuestras columnas y esta variable.

La variable escogida fue DMQMILIZ , e indica si el individuo ha servido en activo en las Fuerzas Armadas, Guardia o Reservas de EE. UU.

- DMQMILIZ = 1: Ha servido en activo.
- DMQMILIZ = 0: No ha servido.


La parte verde en estos gráficos representa la proporción de personas que han servido en el ejército dentro de cada categoría. Nos muestra qué porcentaje de gente en cada grupo tiene experiencia militar.

Cuando la parte verde es grande, significa que un alto porcentaje de personas en esa categoría han servido. Cuando es pequeña, significa que muy pocas personas en ese grupo han tenido experiencia militar. La parte roja, por el contrario, representa a quienes no han servido.

De esta forma, comparando el tamaño de la sección verde entre diferentes categorías, podemos ver dónde la probabilidad de haber servido es mayor o menor. Un grupo con mucho verde indica una alta prevalencia de servicio militar, mientras que un grupo casi todo rojo sugiere que el servicio militar es poco común en esa población.

1. RIAGENDR (género)

- Los hombres presentan una probabilidad significativamente mayor de haber servido.
- Entre las mujeres, la probabilidad es muy baja.



2. RIDAGEYR y DMDHRAGE (edad del participante y del cabeza de hogar)

- Las distribuciones de la clase 1 (personas que han servido) están desplazadas hacia edades mayores.
- En general, a mayor edad, mayor probabilidad de haber servido.

Figura 09: Distribución de RIDAGEYR





Figura 10: Distribución de DMDHRAGE



3. DMDBORN4 (nacido en EE. UU.) y DMDCITZN (ciudadanía)

- Nacer en EE. UU. y ser ciudadano estadounidense se asocian con una probabilidad sustancialmente más alta de servicio militar.
- Los nacidos fuera del país o sin ciudadanía presentan menor probabilidad.

Figura 11: Distribución de DMDBORN4





Figura 12: Distribución de DMDCITZN




4. SIALANG (idioma de la entrevista) y SIAINTRP (uso de intérprete)

- Entrevistas realizadas en inglés y sin intérprete muestran una alta probabilidad de DMQMILIZ=1.
- Entrevistas en español o con intérprete se asocian con una probabilidad baja.

Figura 13: Distribución de SIALANG




Figura 14: Distribución de SIAINTRP



5. DMDHREDU (nivel educativo)

- Se observa un gradiente suave: las personas con educación media o superior tienen mayor probabilidad de haber servido que aquellas con niveles educativos bajos.
- No hay saltos bruscos entre categorías.


Figura 15: Distribución de DMDHREDU



6. RIDRETH3 (raza/origen étnico)

- La probabilidad de haber servido es mayor entre personas **no hispánicas blancas** o **no hispánicas negras**.
- Es menor entre **asiáticos no hispánicos** y **grupos hispanos**.


Figura 16: Distribución de RIDRETH3



7. DMDFMSIZ (tamaño de la familia)

- Las personas que han servido tienden a pertenecer a familias ligeramente más pequeñas.
- No obstante, el solapamiento entre grupos es alto, por lo que el efecto es débil.


Figura 17: Distribución de DMDFMSIZ



8. DMDHRGND (género del cabeza de hogar)

- Cuando el cabeza de hogar es hombre, la probabilidad de haber servido es mayor.

Figura 18: Distribución de DMDHRGND




a. Interacciones de las Variables

Para comprobar si existen interacciones relevantes entre las variables del modelo, realizamos un análisis visual exploratorio de las combinaciones más prometedoras.

El objetivo es identificar si el efecto de una variable sobre el nivel de ingresos familiares (INDFMPIR) cambia dependiendo del nivel de otra variable, es decir, si el impacto de una característica depende de otra.

Comenzamos creando gráficos comparativos y boxplots que muestran cómo se comporta INDFMPIR en distintas combinaciones de factores. Por ejemplo, analizamos si el idioma de la entrevista (SIALANG) y el uso de intérprete (SIINTRP) parecían influir conjuntamente en los ingresos.

Figura 19: Plots SIALANG y SIINTRP




Como se puede ver no se observa ninguna interacción aparente entre estas variables.

Después, examinamos otras posibles combinaciones que teóricamente podían tener interacción, como:

- Educación × Género
- Lugar de nacimiento × Idioma
- Educación × Idioma
- Lugar de nacimiento × Ciudadanía
- Uso de intérprete × Ciudadanía

En algunos de estos gráficos, por ejemplo Educación × Género se observan diferencias aparentes entre grupos, lo que visualmente sugiere una posible interacción.


Figura 20: Educación x Género sobre INDFMPIR



Sin embargo, al incluir estas combinaciones en modelos estadísticos formales, la mayoría no resultan estadísticamente significativas al incluirlas en los posteriores modelos.

La única interacción que muestra significancia estadística real es la de Educación × Idioma (DMDEDUC2 × SIALANG). Esta relación indica que el efecto del nivel educativo sobre los ingresos familiares varía según el idioma en que se realizó la entrevista.

Figura 21: Plot Educación x Language



En resumen, aunque los gráficos iniciales parecen mostrar varias interacciones posibles, las pruebas estadísticas demostraron que solo una (Educación × Idioma) tiene relevancia real en el modelo. Este proceso evidencia la importancia de combinar la observación visual con el análisis estadístico: lo que a primera vista puede parecer un patrón interesante, no siempre se sostiene al evaluar su significancia matemática.

iv. Conclusiones

a. Estructura de Variables y Sesgo Univariado

Las variables numéricas muestran distribuciones heterogéneas:

- Distribuciones estables: La variable RIDAGEYR (edad) es aproximadamente simétrica, lo que la hace apta para modelos paramétricos.
- Asimetría pronunciada: Variables clave como WTINT2YR (peso de entrevista) e INDFMPIR (ratio de pobreza) presentan una fuerte asimetría positiva, con colas largas hacia la derecha. Esta característica exige el uso de transformaciones logarítmicas o estimadores robustos para estabilizar la varianza y reducir la influencia de outliers en el modelo.
- Baja variabilidad: Variables categóricas como RIDSTATR (estado de examen) muestran una variabilidad muy baja, concentrándose en categorías dominantes.

b. Relaciones Bivariadas y Detección de Features del modelo binario

El análisis bivariado respecto a la variable objetivo latente el servicio militar (DMQMILIZ) identificó *features* con alta capacidad discriminativa:

- Factores demográficos clave: Los hombres (RIAGENDR) y las personas de mayor edad (RIDAGEYR) tienen una probabilidad significativamente superior de haber servido.
- Contexto social: Nacer en EE. UU. (DMDBORN4) y realizar la entrevista en inglés y sin intérprete (SIALANG, SIAINTRP) están fuertemente asociados con una mayor probabilidad de servicio militar.

c. Interacciones de Features

La exploración de interacciones sobre la variable de resultado clave (INDFMPIR, ratio de pobreza) determinó la necesidad de incluir términos de interacción en el modelo.

- Interacción significativa: La única interacción estadísticamente relevante fue Educación × Idioma (*DMDEDUC2* × *SIALANG*). Esta relación indica que el efecto del nivel educativo sobre los ingresos familiares no es constante, sino que varía dependiendo del idioma en que se realizó la entrevista.

d. Final Thoughts

La modelización requerirá un preprocesamiento cuidadoso para manejar el sesgo en variables como INDFMPIR y la incorporación explícita de la interacción Educación × Idioma para capturar la complejidad real de la relación con los ingresos familiares.

3. Generalized Linear Models (GLMz)

i. Model fitting

a. Modelo 1 (familia gaussiana, link identidad)

Como primer paso, probamos un modelo lineal generalizado utilizando la familia gaussiana con enlace identidad. A pesar de que sabíamos de antemano que esta elección probablemente no sería la más adecuada, consideramos importante evaluar su desempeño como punto de partida.

La razón principal de esta expectativa es que la variable objetivo (*INDFMPIR*, que representa el índice de ingresos respecto al umbral de pobreza) no sigue una distribución normal. En particular, se observa una fuerte acumulación de valores en 5, debido a que el conjunto de datos agrupa todos los valores de 5 en adelante como “5 o más”. Esta naturaleza genera una distribución asimétrica con cola corta, lo que rompe uno de los supuestos básicos del modelo gaussiano.

El modelo inicial estimado fue:

```
None
mlgz <- glm(INDFMPIR ~ . - DMQMILIZ, dd, family = gaussian(link=identity))
summary(mlgz)
```

Como veremos posteriormente, la [validación del modelo](#) nos dejó con la necesidad de probar con nuevos modelos, que se definen a continuación.

b. Modelo 2 (familia gaussiana, link log)

A continuación, ajustamos un nuevo modelo pero en este caso cambiando la familia link a un link logarítmico, para observar si existía alguna mejora sustancial que nos aportará un modelo que se ajustará adecuadamente a los datos.

El modelo ajustado fue:

```
None
mlgz2 <- glm(INDFMPIR ~ .+ DMEDEDUC2*SIALANG - DMQMILIZ, dd, family =
gaussian(link=log))
```

El modelo mejoró sustancialmente, sin embargo, la validación demostró que no era suficiente, por lo que decidimos probar a cambiar la familia del modelo.

b. Modelo 3 (familia Gamma, link log)

Decidimos probar con la familia Gamma, que se suele ajustar debidamente a variables como ratios de pobreza.

El modelo ajustado con familia gamma y link log se ajustó de la siguiente manera:

```
None  
mlgz3 <- glm(INDFMPIR ~ . + DMDEDUC2*SIALANG, dd, family = Gamma(link=log))  
summary(mlgz3)
```

A partir de la validación del modelo, decidimos quedarnos con este modelo.

ii. Model Validation (deviance statistic)

a. Validación Numérica (Modelo 1)

Tras ajustar el primer modelo con familia gaussiana y link identidad, se obtuvo una desviación residual de 7425.5 con 5052 grados de libertad.

Cuando se evaluó su capacidad explicativa mediante el estadístico de la devianza,

$$(1 - pchisq(7425.5, 5052)) \approx 0$$

El resultado fue prácticamente 0, lo que indica que el modelo no consigue explicar adecuadamente la variabilidad de los datos. En otras palabras, las diferencias entre los valores observados y los predichos son demasiado grandes para ser atribuibles al azar, lo que sugiere un mal ajuste global.

b. Validación Numérica (Modelo 2)

En este caso, en el modelo con familia gaussiana y link logarítmico, se obtuvo una desviación residual de 7680.1 con 5048 grados de libertad.

$$(1 - pchisq(7680.1, 5048)) \approx 0$$

Cuando se evaluó su capacidad explicativa mediante el estadístico de la devianza el resultado fue de nuevo prácticamente 0, lo que indica que el modelo no consigue explicar adecuadamente la variabilidad de los datos.

c. Validación Numérica (Modelo 3)

Los resultados mejoraron significativamente con este nuevo modelo ajustado de familia Gamma y link logarítmico, debido a que nos proporcionó una desviación residual de 1906.1 en 5048 grados de libertad.


$$(1 - pchisq(1906.1, 5048)) \approx 1$$

Al comprobarlo mediante el estadístico de la devianza el resultado fue de prácticamente 1, lo que indica que el modelo se adapta adecuadamente y nos proporciona una gran explicabilidad de los datos.

d. Validación Gráfica (Modelo 1)

A pesar de los resultados numéricos desfavorables, se llevó a cabo una validación gráfica de los residuos para observar visualmente la calidad del ajuste. El gráfico de residuos mostró un patrón razonablemente disperso y sin grandes desviaciones sistemáticas, lo que sugiere que el modelo no estaba completamente desalineado con los datos.

Figura 22: Residuals del Modelo 1




Sin embargo, el hecho de que el estadístico de la devianza indicará un ajuste deficiente llevó a la conclusión de que, aunque la validación gráfica parecía decente, el modelo no era estadísticamente adecuado para los datos, que era el resultado esperado.

e. Validación Gráfica (Modelo 2)

En este caso se volvió a comprobar los residual plots del modelo para comprobar por validación gráfica el modelo ajustado con link logarítmico.

Figura 23: Residuals del Modelo 2




El gráfico de residuos volvió a mostrar un patrón razonablemente disperso y sin grandes desviaciones sistemáticas. Pero en este caso decidimos probar a cambiar la familia del modelo ajustado a una Gama para observar el nuevo ajuste del modelo y su precisión.

f. Validación Gráfica (Modelo 3)

Al realizar los residual plots de este modelo con familia gaussiana y link logarítmico, podemos observar que la varianza es significativamente peor que en los modelos anteriores, probablemente debido a la acumulación de datos debido a como está definida nuestra variable objetivo, y a la acumulación de valores en el 5.

Figura 24: Residuals del Modelo 3



Sin embargo, decidimos quedarnos con este último modelo debido a que el estadístico de la devianza nos proporciona un resultado mucho más positivo que en los otros modelos.

g. ANOVAS

Una vez ajustado el modelo, realizamos una prueba ANOVA para evaluar la importancia relativa de cada variable y explorar la posibilidad de simplificar el modelo. Comprobamos los tres modelos propuestos (Gaussiano, Gaussiano con enlace logarítmico y Gamma con enlace logarítmico) y encontramos que la significancia de las variables era similar en todos ellos. Esta consistencia nos permitió identificar cuáles eran verdaderamente necesarias y cuáles podrían ser redundantes.

Tabla 06: Resultados Prueba ANOVA

Variable	LR Chisq	Df	Pr(>Chisq)	Significancia
RIAGENDR	1.98	1	1.594.543	
RIDAGEYR	38.66	1	5,05E-07	***
RIDRETH3	229.19	5	< 2.2e-16	***
DMQMILIZ	0.02	1	8.890.934	
DMDBORN4	1.00	1	3.174.280	
DMDCITZN	2.99	1	835.421	.
DMDEDUC2	105.30	4	< 2.2e-16	***
SIALANG	9.57	1	19.770	**
SIINTRP	6.73	1	94.758	**
DMDFMSIZ	6.12	1	133.553	*
DMDHHSZA	181.32	1	< 2.2e-16	***
DMDHHSZB	110.70	1	< 2.2e-16	***
DMDHHSZE	3.93	1	474.130	*
DMDHRGND	10.31	1	13.196	**
DMDHRAGE	1.82	1	1.774.029	
DMDHRBR4	0.97	1	3.239.557	
DMDHREDU	152.27	4	< 2.2e-16	***
DMDHRMAR	244.90	5	< 2.2e-16	***
WTINT2YR	466.36	1	< 2.2e-16	***
DMDEDUC2:SIALANG	20.17	4	4.633	**

Sin embargo, los resultados mostraron que, aunque algunas variables no alcanzaron significancia estadística, su contribución conceptual seguía siendo valiosa.

Aunque el modelo incluye algunas variables que no alcanzan significancia estadística, decidimos mantenerlas en lugar de eliminarlas. Esta decisión se fundamenta en que estas variables capturan características demográficas y sociales esenciales del individuo que, más allá de su valor estadístico inmediato, representan dimensiones importantes del individuo.

Variabes como el género, la etnicidad, el lugar de nacimiento, la ciudadanía, el tamaño de la familia y la estructura del hogar son características intrínsecas que definen el perfil de los

participantes. Aunque algunas no muestren efectos estadísticamente significativos en este análisis específico, su inclusión mejora la validez conceptual del modelo y reduce el riesgo de sesgo de omisión variable.

En otras palabras, estas no son variables "ruidosas" o arbitrarias, sino factores demográficos fundamentales que tiene sentido controlar en cualquier análisis sobre el ratio de ingresos, incluso cuando su contribución estadística es modesta.

iii. Model Interpretation

A partir de nuestro modelo con familia Gamma y link logarítmico, analizaremos los diferentes coeficientes para observar cómo afectan las diversas características de los individuos en la variable objeto de estudio, el ratio de pobreza del individuo.

1. Género (RIAGENDR)

El coeficiente para la variable categórica de género, respecto a la categoría inicial (es decir, diferencia entre ser hombre o mujer) es de -0.0247 ($p = 0.159$, no significativo). Si observamos el porcentaje aplicando $\exp(-0.0247) \approx 0.976$ podemos deducir que el hecho de cambiar de la primera a la segunda categoría reduce el porcentaje en un -2.4% .

Aunque no es estadísticamente significativo, el modelo sugiere que las mujeres tienen un ratio de ingresos aproximadamente -2.4% menor que los hombres, manteniendo constantes las demás variables. El efecto es pequeño y no robusto, lo que indica que no se detectan diferencias relevantes de ingreso por género una vez controlados otros factores estructurales.

2. Edad (RIDAGEYR)

El coeficiente para la variable de la edad es de 0.00533 ($p < 0.001$, altamente significativo). Si observamos el porcentaje aplicando $\exp(0.00533) \approx 1.0053$ podemos deducir que por cada año adicional de la persona aumenta un $+0.53\%$ la variable objetivo.

Esto significa que cada año adicional de edad se asocia con un aumento de aproximadamente 0.53% en el ratio INDFMPIR. Una persona de 50 años tendría en promedio un 17% más de ingreso relativo que una de 20 años, manteniendo las demás variables constantes. La edad muestra una relación positiva y estadísticamente robusta con el nivel económico.

3. Etnicidad (RIDRETH3)

Tabla 07: Categoría de referencia: Mexican American (1).

Grupo	Coeficiente	exp(coef)	Cambio (%)	Significancia
Other Hispanic (2)	+0.0557	1.057	+5.7%	No significativo
Non-Hispanic White (3)	-0.309	0.734	-26.6%	$p < 2e-16$
Non-Hispanic Black (4)	-0.0089	0.991	-0.9%	No significativo
Non-Hispanic Asian (6)	+0.225	1.252	+25.2%	$p < 1e-7$
Other/Multi-racial (7)	-0.138	0.871	-12.9%	$p = 0.009$

Como podemos observar, hay diferencias étnicas significativas. Los asiáticos no hispanos presentan un ingreso relativo 25% superior al grupo de referencia, mientras que los blancos no hispanos tienen un ratio 26.6% menor. Estas diferencias sugieren que, tras controlar por educación, edad y otras características, las brechas por grupo étnico persisten, aunque no siguen los patrones tradicionales de desigualdad observados en otros contextos.

4. Nivel Educativo (DMDEDUC2)

Tabla 08: Referencia: menos de 9 años de educación.

Nivel educativo	Coef.	exp(coef)	Cambio (%)	Signif.
High school graduate (2)	0.197	1.218	+21.8%	$p < 0.001$
Some college (3)	0.334	1.396	+39.6%	$p < 0.001$
Associate degree (4)	0.434	1.543	+54.3%	$p < 0.001$
College graduate or above (5)	0.571	1.770	+77.0%	$p < 0.001$

La educación es el factor más potente del modelo. Cada nivel adicional de estudios aumenta de forma significativa el ratio de ingresos: terminar secundaria eleva el ingreso relativo un 22%, y tener título universitario casi lo duplica. Esto reafirma que la educación actúa como un factor protector frente a la pobreza relativa.

5. Idioma e Intérprete (SIALANG, SIAINTRP)

El hecho de cambiar a SIALANG2 (haber hecho entrevista en español respecto a haberla hecho en inglés) nos da un coeficiente de +0.0526 , si lo expresamos con $\exp(0.0526)$ podemos observar que nos da 1.054, es decir, aumenta un +5.4%. Sin embargo, este coeficiente no tiene mucha significancia estadística.

El hecho de tener o no un intérprete presente (SIAINTRP2) nos da un coeficiente de +0.125 , transformado $\exp(0.125) = 1.133$, lo que nos indica que aumenta un +13.3% con un p valor de 0.008, aporta un poco de relevancia estadística.

Podemos deducir que el idioma español no muestra efecto negativo sobre el ingreso, pero la presencia de intérprete sí se asocia a un incremento del 13%. Esto podría indicar que los hogares que requieren intérprete no necesariamente están en situación económica más baja, debido a que pueden permitirse usar un intérprete.

6. Tamaño y Composición del Hogar

- DMDFMSIZ (tamaño del hogar): coef. = +0.0198 transformando con $\exp(0.0198) = 1.020$, es decir, aumenta un +2.0% ($p = 0.013$). Este resultado muestra significancia estadística moderada.
- DMDHHSZA (niños <5 años): coef. = -0.219 transformando con $\exp(-0.219) = 0.803$, lo que indica una reducción del -19.7% ($p < 2e-16$). Este es el factor con mayor impacto negativo y altamente significativo.
- DMDHHSZB (niños 6–17 años): coef. = -0.128 transformando con $\exp(-0.128) = 0.880$, representando una disminución del -12.0% ($p < 2e-16$). También presenta una significancia estadística muy alta.
- DMDHHSZE (adultos ≥ 60 años): coef. = -0.030 transformando con $\exp(-0.030) = 0.970$, mostrando una reducción del -2.9% ($p = 0.047$). Tiene significancia estadística pero con menor relevancia práctica.

Podemos ver que los hogares con más miembros tienden a tener ingresos totales algo mayores (+2%), efecto atribuible al aumento del número de potenciales perceptores de ingresos. Sin embargo, la presencia de dependientes jóvenes reduce considerablemente el ingreso relativo. Los niños menores de 5 años generan el impacto negativo más pronunciado (-19.7%), probablemente debido al incremento significativo de gastos de cuidado y la menor disponibilidad laboral de los adultos para trabajar. Los niños en edad escolar también impactan negativamente (-12.0%), aunque en menor medida, mientras que la presencia de adultos mayores muestra un efecto modesto (-2.9%), sugiriendo que la composición demográfica del hogar es un determinante importante de los ingresos relativos.

7. Género y Edad del Cabeza de Hogar

El hecho de que el hogar esté encabezado por una mujer (DMDHRGND2) nos da un coeficiente de -0.0563, que transformado con $\exp(-0.0563)$ nos proporciona 0.945, es decir, disminuye un -5.5% ($p = 0.001$). Este resultado presenta una significancia estadística considerable, indicando que los hogares con jefatura femenina tienen ingresos un 5.5% menores en promedio, lo que sugiere la existencia de brechas estructurales persistentes en términos de capacidad económica y acceso a oportunidades de generación de ingresos.

Por otro lado, la edad del cabeza del hogar (DMDHRAGE) nos proporciona un coeficiente de -0.0013, que transformado resulta en $\exp(-0.0013) = 0.999$, representando una reducción prácticamente nula del -0.13% ($p > 0.05$). Este coeficiente no presenta significancia estadística relevante, lo que nos indica que la edad de la persona que encabeza el hogar no tiene un efecto notorio sobre los ingresos en este contexto particular. Podemos deducir, por tanto, que mientras la jefatura femenina se asocia de manera clara con menores ingresos relativos, la edad del cabeza del hogar no constituye un factor determinante en la variación de los ingresos del grupo estudiado.

8. Educación del Cabeza de Hogar (DMDHREDU)

Tomando como referencia los hogares cuyo cabeza tiene menos de 9 años de educación, se observa que a medida que aumenta el nivel educativo del cabeza del hogar, el ratio de ingresos mejora de manera notablemente progresiva. Específicamente, aquellos hogares cuyo cabeza es graduado de high school (nivel 2) presentan ingresos un +8.7% mayores. Este incremento se reduce considerablemente en los hogares con algo de educación universitaria (nivel 3), alcanzando un +17%, y continúa ampliándose con aquellos que poseen un associate degree (nivel 4), que muestran un +29.8% de mejora. El efecto más pronunciado se observa en los hogares cuyo cabeza es graduado universitario (nivel 5), donde los ingresos aumentan hasta un +65.5% en comparación con la categoría de referencia.

Estos resultados demuestran que el nivel educativo del cabeza de hogar constituye un predictor fuerte e independiente del bienestar económico del hogar, con un patrón de retorno creciente a medida que se alcanzan niveles educativos más altos. Esta relación refuerza el patrón ya observado en la educación individual y subraya la importancia crítica de la inversión en capital humano como determinante fundamental de la capacidad económica y el bienestar material de los hogares.

9. Estado Civil del Cabeza de Familia (DMDHRMAR)

Tabla 09: Referencia: casado (1)

Estado civil	Coef.	exp(coef)	Cambio (%)
Viudo (2)	-0.189	0.828	-17.2%
Divorciado (3)	-0.294	0.745	-25.5%
Separado (4)	-0.305	0.737	-26.3%
Nunca casado (5)	-0.354	0.702	-29.8%
Viviendo en pareja (6)	-0.174	0.840	-16.0%

Podemos observar que todas las categorías distintas a “casado” muestran reducciones significativas en el ratio de ingresos. Estar casado aparece como un factor protector sólido frente a la pobreza relativa, lo que sugiere que los hogares con dos adultos estables presentan ventajas económicas sostenidas.

10. Interacción Educación × Idioma (DMDEDUC2 × SIALANG)

La interacción es globalmente significativa ($p < 0.05$). Los efectos para entrevistados en español muestran que la ventaja de la educación se atenúa:

Tabla 10: Nivel educativo x Español

Nivel educativo × Español	Coef. interacción	Reducción del efecto
High school graduate	-0.145	-13.5% (marginamente significativo)
Some college	-0.296	-25.7%
Associate degree	-0.381	-31.7%
College graduate	-0.349	-29.5%

Esto lo podemos interpretar de la siguiente manera: una persona entrevistada en inglés con educación universitaria tendría un efecto de +77%. Si fue entrevistada en español, su efecto total sería $\exp(0.571 - 0.349) = \exp(0.222) \approx +24.8\%$.

Esto nos indica que la educación sigue siendo un fuerte factor protector, pero su impacto se reduce notablemente entre quienes enfrentan barreras lingüísticas, reflejando cómo la educación se convierte de manera desigual en capital.

11. Ponderación (WTINT2YR)

El peso de diseño de la encuesta (coeficiente: 8.19e-06) es altamente significativo ($p < 2e-16$), lo que indica que este factor juega un papel crucial en los resultados.

Este término refleja cómo la encuesta fue diseñada para asegurar que los resultados sean representativos de la población general, es decir, que los datos obtenidos no solo describan a quienes respondieron, sino que puedan extrapolarse y reflejar las características reales de toda la población estudiada.

12. Conclusiones Generales

El modelo confirma que la educación y el estado civil son los factores más determinantes del nivel de ingresos relativo al umbral de pobreza. También se observan efectos negativos claros asociados con la presencia de hijos pequeños y con hogares encabezados por mujeres. La etnicidad y el idioma introducen matices importantes: los asiáticos no hispanos tienen ventaja económica significativa, mientras que el uso del español, combinado con menor acceso educativo, reduce parcialmente los beneficios de la educación. En conjunto, el modelo captura de manera robusta los principales determinantes socioeconómicos del bienestar económico dentro de la muestra.

iv. Presentación Modelo Binario

La variable DMQMILIZ indica si un individuo ha servido activamente en las Fuerzas Armadas de Estados Unidos (0 = no, 1 = sí). Antes de ajustar el modelo, se eliminaron las observaciones con datos faltantes para esta variable y para todas las covariables relevantes, de forma que el análisis se realizará sobre un conjunto completamente observado.

El conjunto de datos presentaba un fuerte desbalance de clases: aproximadamente 4682 observaciones en la categoría "no ha servido" (0) frente a solo 494 observaciones en la categoría "sí ha servido" (1). Este desbalance representa un problema conocido en modelado predictivo, ya que el algoritmo de regresión logística tiende a favorecer la predicción de la clase mayoritaria, subestimando la capacidad para identificar correctamente los casos de la clase minoritaria.

Para mitigar este problema, se implementó un submuestreo aleatorio de la clase mayoritaria. Específicamente, se seleccionó aleatoriamente un número de casos de la clase 0 igual al número de casos de la clase 1 (494 observaciones), de modo que ambas categorías tuvieran exactamente el mismo peso. Esto generó un dataset balanceado con 494 individuos en cada categoría, permitiendo que el modelo se ajusta bajo una distribución equilibrada de clases.

La ventaja de este enfoque es que permite evaluar cómo el desbalanceo afectaba al modelo original, y si los resultados se mantenían robustos ante cambios en la composición de la muestra.

v. Binary Model fitting

Se estimaron dos modelos, ambos con la variable dependiente DMQMILIZ:

a. Modelo 1 (balanced data)

Modelo 1 (Balanceado): Ajustado sobre el dataset con clases equilibradas (494 observaciones de cada clase). Incluimos todas las variables explicativas disponibles.

```
None  
summary(mb_balanced <- glm(DMQMILIZ ~ ., dd_binary_balanced,  
family=binomial(link='logit')))
```

b. Modelo 2 (unbalanced data)

Modelo 2 (Desbalanceado): Ajustado directamente sobre los datos originales con su distribución natural (4682 casos de clase 0, 494 de clase 1). También incluyó todas las variables disponibles.

```
None  
summary(mb <- glm(DMQMILIZ ~ ., dd_binary, family=binomial(link='logit')))
```

En ambos casos se utilizó la función GLM con familia binomial y enlace logit.

vi. Binary Model Validation

a. AUC - ROC validation

Para evaluar la capacidad discriminativa de ambos modelos calculamos las curvas ROC (Receiver Operating Characteristic) y el área bajo la curva (AUC). El AUC mide la probabilidad de que el modelo clasifique correctamente un caso positivo y uno negativo seleccionados aleatoriamente, con valores cercanos a 1 indicando excelente desempeño y valores cercanos a 0.5 reflejando clasificación aleatoria.

Resultados:

Modelo balanceado: AUC = 0.9038

Modelo desbalanceado: AUC = 0.9085

Ambos modelos alcanzaron un AUC superior a 0.90, demostrando una excelente capacidad para distinguir entre individuos que sirvieron o no en las Fuerzas Armadas. La diferencia entre ambos es de apenas 0.0047, siendo prácticamente despreciable.

b. Validación Gráfica

El examen visual de los residual plots reveló diferencias claras entre los enfoques:


En el modelo balanceado, los residuos se concentran alrededor de cero con una varianza moderada y controlada, indicando un ajuste más homogéneo y una menor influencia de valores extremos.

En el modelo desbalanceado, los residuos muestran mayor dispersión y presencia de valores atípicos más pronunciados, reflejando una cierta sensibilidad a los casos extremos y heterocedasticidad moderada.

A pesar de estas diferencias en la dispersión, ninguno de los modelos evidencia un patrón sistemático de error, lo que sugiere una especificación correcta en ambos casos.


Balanced:

Figura 25: Balanced Predictor Lineal



Unbalanced:

Figura 26: Unbalanced Predictor Lineal



c. Simplificación modelo binario

Una vez ajustados los modelos completos, se realizó un análisis de varianza (ANOVA) para evaluar la importancia relativa de cada variable e identificar oportunidades de simplificación.

El ANOVA Tipo II reveló que muchas variables no alcanzaron significancia estadística en ninguno de los dos modelos (balanceado y desbalanceado). Esto indicaba que existía la posibilidad de crear un modelo más parsimonioso sin sacrificar capacidad predictiva.

Tabla 11: Resultados ANOVA Test 2

Variable	LR Chisq	Df	Pr(>Chisq)	Significancia
RIAGENDR	197.784	1	< 2.2e-16	***
RIDAGEYR	40.205	1	2,29E-07	***
RIDRETH3	24.059	5	2.115	***
DMDBORN4	1.655	1	1.982.179	
DMDCITZN	17.471	1	2,92E-02	***
DMDEDUC2	20.140	4	4.686	***
SIALANG	6.678	1	97.635	**
SIINTRP	63	1	8.011.425	
DMDFMSIZ	253	1	6.148.428	
DMDHHSZA	60	1	8.061.234	
DMDHHSZB	10	1	9.216.309	
DMDHHSZE	133	1	7.157.126	
DMDHRGND	44	1	8.340.955	
DMDHRAGE	5.411	1	200.128	*
DMDHRBR4	27	1	8.683.717	
DMDHREDU	7.744	4	1.014.217	
DMDHRMAR	10.012	5	748.836	.
WTINT2YR	47	1	8.279.021	
INDFMPIR	6.039	1	139.918	*

Se ajustó un modelo nuevo reducido incluyendo solo las variables más relevantes: RIAGENDR, RIDAGEYR, RIDRETH3, DMDCITZN, DMDEDUC2 y SIALANG:

None

```
summary(mb2_balanced <- glm(DMQMILIZ ~ + RIAGENDR + RIDAGEYR + RIDRETH3 +
DMDCITZN + DMDEDUC2 + SIALANG, dd_binary_balanced,
family=binomial(link='logit')))
```


La comparación estadística entre el modelo completo y el reducido (mediante anova) mostró un p-valor de 0.0658, que es mayor a 0.05. Esto significa que no hay diferencia significativa entre ambos modelos: el modelo simplificado retiene prácticamente toda la información del modelo completo sin perderla de manera estadísticamente relevante.

Analysis of Deviance Table

```
Model 1: DMQMILIZ ~ RIAGENDR + RIDAGEYR + RIDRETH3 + DMDBORN4 + DMDCITZN +
  DMDEDUC2 + SIALANG + SIAINTRP + DMDFMSIZ + DMDHHSZA + DMDHHSZB +
  DMDHHSZE + DMDHRGND + DMDHRAGE + DMDHRBR4 + DMDHREDU + DMDHRMAR +
  WTINT2YR + INDFMPIR
Model 2: DMQMILIZ ~ +RIAGENDR + RIDAGEYR + RIDRETH3 + DMDCITZN + DMDEDUC2 +
  SIALANG
  Resid. Df Resid. Dev  Df Deviance Pr(>Chi)
1         956       715.41
2         975       744.42 -19   -29.014  0.06576 .
```

Además, el modelo reducido mantuvo un AUC de 0.905 cuando se evaluaba sobre el conjunto de datos original (desbalanceado), confirmando que la simplificación no comprometía la capacidad predictiva, sumado a que los residual plots mostraban un comportamiento muy similar al modelo anterior.

d. Resumen

El análisis comparativo entre modelos balanceados y desbalanceados, así como entre modelos completos y simplificados, demuestra que el desbalanceo de clases original afectaba la interpretabilidad del modelo pero no comprometía significativamente su rendimiento predictivo. Además, el modelo simplificado (con seis variables) funciona prácticamente igual que el modelo completo (con diecinueve variables), pero ofrece mayor parsimonia e interpretabilidad. Ambos enfoques convergen en conclusiones similares respecto a qué variables son importantes para predecir la participación en el servicio militar.

Por estas razones, seleccionamos el modelo reducido como la versión final para la interpretación, ya que ofrece un equilibrio óptimo entre capacidad predictiva, estabilidad estadística y facilidad de interpretación.

vii. Interpretación Modelo Binario

Durante la interpretación del modelo binario con datos balanceados y con complejidad reducida, nos surgió un problema de quasi-separación, es decir separación casi perfecta en una de las variables, ciudadanía (DMDCITZN)

El coeficiente para no ciudadanos (DMDCITZN2) era de -17.22 con un error estándar gigantesco (≈ 566.9) $\rightarrow \exp(-17.22) \approx 3.3e-8$.

Esto es signo de separación completa o casi completa: en los datos balanceados prácticamente no hay no-ciudadanos que hayan declarado haber servido, por lo que el estimador es inestable.

Nuestra solución ha sido crear un nuevo modelo con una regresión penalizada (firth regression). Este modelo nos dió un área debajo de la curva ROC de 0.9052. Sin embargo, no podemos ver los residual plots debido a las diferencias de los métodos entre librerías de definición del modelo de regresión penalizada.

El modelo resultante mantiene las mismas variables significativas que en el ajuste clásico, pero con coeficientes algo atenuados (más conservadores), lo cual es esperable tras la penalización.

1. Género (RIAGENDR)

El coeficiente para las mujeres (RIAGENDR2) es de -2.92 , que transformado con $\exp(-2.92)$ nos proporciona aproximadamente 0.054. Esto significa que, manteniendo el resto de factores constante, las mujeres tienen alrededor del 5.4% de las probabilidades de haber servido en el ejército en comparación con los hombres, o expresado de otra manera, los hombres presentan aproximadamente 18 veces más probabilidades de haber servido. Este efecto es altamente significativo ($p < 0.001$), lo que indica un resultado muy robusto y confiable. La magnitud de esta diferencia se alinea con lo esperado considerando las diferencias históricas en las políticas de reclutamiento y acceso al servicio militar, donde históricamente ha habido restricciones o limitaciones en la participación de las mujeres. Este patrón refleja cómo factores estructurales e históricos del sistema militar han generado disparidades profundas en la composición del personal que ha servido.

2. Edad (RIDAGEYR)

El coeficiente para la edad es de 0.0529, que transformado con $\exp(0.0529)$ nos proporciona aproximadamente 1.054. Esto significa que por cada año adicional de edad, las probabilidades de haber servido en el ejército aumentan en un 5.4%. Para ilustrar este efecto, una persona de 40 años tiene aproximadamente 2.4 veces más probabilidades de haber servido que una persona de 20 años, manteniendo las demás variables constantes. Este resultado es altamente significativo ($p < 0.001$), indicando un efecto claro y robusto. La magnitud del impacto es coherente con la lógica de acumulación de experiencia a lo largo de la vida, reflejando cómo a medida que las personas envejecen, aumenta la probabilidad de que hayan tenido la oportunidad de servir en algún momento de sus vidas.

3. Etnicidad (RIDRETH3)

Tomando como categoría de referencia a los Mexican American, se observan diferencias significativas en las probabilidades de haber servido según el origen étnico. Los Other Hispanic presentan un coeficiente de 1.36, que transformado con $\exp(1.36)$ nos proporciona aproximadamente 3.89, es decir, tienen probabilidades casi 4 veces mayores ($p \approx 0.005$). Los Non-Hispanic White muestran un coeficiente de 0.78, resultando en $\exp(0.78) \approx 2.17$, lo que representa probabilidades aproximadamente el doble ($p \approx 0.026$). Los Non-Hispanic Black presentan un coeficiente de 1.15, transformado en $\exp(1.15) \approx 3.16$, mostrando un efecto claramente positivo ($p \approx 0.002$). En contraste, los Non-Hispanic Asian tienen un coeficiente de -1.06 , que transformado resulta en $\exp(-1.06) \approx 0.35$, representando probabilidades un 65% menores respecto al grupo de referencia ($p \approx 0.038$). Finalmente, los Other/Multi-racial presentan un coeficiente de 1.31, equivalente a $\exp(1.31) \approx 3.71$, mostrando probabilidades significativamente más altas ($p \approx 0.020$).

En términos generales, se mantienen las diferencias étnicas observadas en análisis previos, aunque algo suavizadas. Los grupos Non-Hispanic Black, Other Hispanic y Other/Multi-racial muestran mayor probabilidad de servicio militar, mientras que los asiáticos no hispanos presentan una menor probabilidad relativa. Estas diferencias pueden reflejar variaciones en factores culturales, generacionales y en la composición migratoria de cada grupo, así como posibles diferencias en el acceso a la información sobre oportunidades de servicio o en las motivaciones para alistarse.

4. Ciudadanía (DMDCITZN)

El coeficiente para el estatus de ciudadanía es de -3.84 , que transformado con $\exp(-3.84)$ nos proporciona aproximadamente 0.021. Esto significa que los no ciudadanos tienen aproximadamente el 2% de las odds de haber servido respecto a los ciudadanos, es decir, unas 50 veces menos probabilidad de haber servido. Este resultado es altamente significativo ($p < 0.001$), indicando un efecto muy robusto y confiable. A diferencia de análisis previos donde el coeficiente era inestable, en este modelo el efecto se estima de forma controlada y robusta, permitiendo una interpretación más sólida.

El resultado es coherente con la lógica del acceso limitado al servicio militar para no ciudadanos, reflejando cómo los requisitos legales y de elegibilidad del sistema militar crean barreras sustantivas que prácticamente excluyen a esta población de la oportunidad de servir.

5. Nivel educativo (DMDEDUC2)

Tomando como categoría de referencia la educación básica, se observan diferencias progresivas en las probabilidades de haber servido según el nivel educativo alcanzado. Los graduados de high school presentan un coeficiente de 0.05, que transformado con $\exp(0.05)$ nos proporciona aproximadamente 1.05, aún así, no representa un efecto significativo estadísticamente. Sin embargo, aquellos con algo de educación universitaria muestran un coeficiente de 1.15, resultando en $\exp(1.15) \approx 3.16$, es decir, probabilidades tres veces mayores ($p \approx 0.048$). El efecto se acentúa considerablemente en quienes tienen un associate degree o educación universitaria parcial, con un coeficiente de 1.65 transformado en $\exp(1.65) \approx 5.21$, representando probabilidades cinco veces mayores ($p \approx 0.005$), un

efecto muy significativo. Los graduados universitarios presentan un coeficiente de 1.48, equivalente a $\exp(1.48) \approx 4.40$, también significativo ($p \approx 0.012$).

La probabilidad de haber servido aumenta de forma clara y progresiva con el nivel educativo, siendo especialmente pronunciado el salto hacia la educación postsecundaria. Aquellos con educación postsecundaria presentan probabilidades entre 3 y 5 veces mayores que quienes tienen solo educación básica. Este patrón podría reflejar diferencias generacionales en el acceso al servicio militar, variaciones en las oportunidades disponibles para distintos grupos educativos, o diferencias en la disposición a reportar y documentar experiencias de servicio militar según el nivel de escolarización.

6. Idioma de la entrevista (SIALANG)

El coeficiente para ser entrevistado en español (SIALANG2) es de -2.45 , que transformado con $\exp(-2.45)$ nos proporciona aproximadamente 0.086. Esto significa que las personas entrevistadas en español tienen alrededor del 8.6% de las probabilidades de haber servido respecto a las entrevistadas en inglés, es decir, unas 12 veces menos probabilidad de haber servido. Este resultado es significativo ($p \approx 0.005$), indicando un efecto grande y robusto que se mantiene incluso cuando se controlan otras variables. Esta gran diferencia probablemente está relacionada con la composición migratoria de la población, ya que quienes son entrevistados en español tienden a ser inmigrantes más recientes o de primera generación, quienes naturalmente tienen menor probabilidad de haber servido en el ejército estadounidense debido a su tiempo más limitado de residencia en el país o a su estatus de ciudadanía. El patrón refleja cómo los factores migratorios y de tiempo de permanencia en Estados Unidos son determinantes cruciales en el acceso histórico al servicio militar.

7. Conclusión general

Los resultados ofrecen una representación más estable y confiable de los factores asociados al servicio militar. El género, la edad, la educación y el idioma siguen siendo los predictores más relevantes en la determinación de quién ha servido, mientras que la etnicidad y la ciudadanía también muestran impactos significativos.

Aunque los ajustes técnicos mejoran la fiabilidad de las estimaciones, no modifican la interpretación sustantiva de los hallazgos. En términos prácticos, estos resultados proporcionan una fotografía robusta de cómo diferentes características demográficas, educativas y migratorias se asocian con la experiencia de servicio militar. Los patrones revelan que el acceso al servicio militar no es aleatorio, sino que responde a dinámicas claras ligadas a oportunidades históricas, restricciones legales y composición de la población según origen y ciudadanía. Las diferencias más pronunciadas se encuentran en el género —donde los hombres tienen probabilidades drásticamente mayores—, la ciudadanía —que prácticamente excluye a no ciudadanos— y el idioma —reflejando la brecha entre poblaciones migrantes recientes y establecidas—, mientras que factores como la educación y la edad muestran efectos progresivos pero menos extremos.

4. Time Series (TS)

i. Selección de Dataset

El análisis de series temporales requiere observaciones secuenciales a intervalos regulares. El dataset utilizado en análisis previos no cumplía este requisito. Por ello, adoptamos el conjunto de datos CPS ASEC de tasas de pobreza, que proporciona:

- Observaciones anuales consistentes desde 1959 hasta 2024 (65 años)
- Tasas de pobreza (PCTPOV) desagregadas por categoría demográfica (RACE_NAME)
- Cobertura completa de Estados Unidos

El dataset tiene las siguientes columnas:

Tabla 12: Descripción Dataset TimeSeries

Nombre de la columna	Descripción
PCTPOV	Tasa de pobreza en porcentaje para el grupo y el año (puntos porcentuales). Aproximadamente, $PCTPOV = 100 * POV / POP$.
POV	Número de personas en situación de pobreza (conteo) para el grupo y el año.
POP	Población total (denominador) para el grupo y el año.
time	Año de la estimación (anual).
RACE	Código numérico para la categoría demográfica (agrupación por raza/etnicidad).
us	Indicador geográfico 1 = Total de Estados Unidos (agregado nacional).
RACE_CODE	Código numérico de raza/etnicidad (misma codificación que RACE, incluido por compatibilidad).
RACE_NAME	Etiqueta legible para el grupo (por ejemplo, "Todas las razas", "Blanco", "Negro", "Hispano (de cualquier raza)", "Solo blanco, no hispano", "Solo asiático").

Un desafío importante surgió del cambio en 2002 en la clasificación racial del censo, que introdujo categorías como "White Alone, Not Hispanic". Para mantener la comparabilidad temporal, consolidamos todas las categorías en cinco grupos consistentes:

- Total (población general)
- White (blancos)
- Black (afroamericanos)
- Hispanic (hispanos/latinos)
- Asian (asiáticos)

Tabla 13: Armonización del Dataset

group	RACE_NAME	start_year	end_year	n_years
<i>All</i>	All Races	1959	2024	66
<i>Asian</i>	Asian Alone	2002	2024	23
<i>Asian</i>	Asian and Pacific Islander	1987	2001	15
<i>Black</i>	Black	1959	2001	37
<i>Black</i>	Black Alone	2002	2024	23
<i>Hispanic</i>	Hispanic (of any race)	1972	2024	53
<i>White</i>	White	1959	2001	43
<i>White</i>	White Alone, not Hispanic	2002	2024	23

Para "White" en años post-2002, priorizamos "White Alone, Not Hispanic" para excluir hispanos blancos y mantener grupos mutuamente exclusivos.

ii. Preguntas a Investigar

Nuestra pregunta central de investigación busca encontrar qué grupos demográficos experimentaron las dificultades económicas más severas durante cada recesión. Nos pareció interesante el hecho de hacer múltiples análisis de series temporales para diferentes rangos de tiempo para luego compararlos.

Textproto

¿Qué grupos demográficos experimentaron los incrementos más severos en pobreza durante cada crisis económica?

Definimos el impacto como el cambio en puntos porcentuales entre:

- Pico: La tasa de pobreza máxima observada durante la crisis
- Baseline: El promedio de las tasas de pobreza en los 3 años previos

Por ejemplo, si la tasa de pobreza hispana era 22% en promedio (1977-1979) y alcanzó 29.9% en 1982, el impacto fue +7.9 pp.

Tras investigar históricamente que recesiones serían interesantes, decidimos centrarnos en:

1. Recesión de Reagan: 1980-1983 (baseline: 1977-1979)
2. Crisis DotCom: 2001-2003 (baseline: 1998-2000)
3. Gran Recesión: 2008-2010 (baseline: 2005-2007)
4. Pandemia COVID-19: 2020-2021 (baseline: 2017-2019)

iii. Modelo Series Temporales

Para entender la dinámica general de la pobreza en EE.UU., desarrollamos un modelo ARIMA usando la serie "Total Population".


a. Transformación Logarítmica

Aplicamos

```
Rust  
log(PCTPOV)
```

para estabilizar la varianza a lo largo de los 65 años de datos. Esta transformación es estándar cuando la variabilidad de una serie aumenta con su nivel.

Figura 27: Transformación Logarítmica



b. Diferenciación para Estacionariedad

La serie mostraba una raíz unitaria (tendencia no estacionaria), por lo que calculamos las diferencias de primer orden:

TypeScript


```

$$\Delta \log(\text{PCTPOV}_t) = \log(\text{PCTPOV}_t) - \log(\text{PCTPOV}_{t-1})$$

```

Esto nos da $d=1$ en la notación $\text{ARIMA}(p,d,q)$.

Figura 28: ACF y PACF Inicial



c. Identificación del Modelo

Analizando los gráficos ACF y PACF identificamos un patrón autorregresivo, lo que nos llevó a probar modelos $\text{ARIMA}(p,1,0)$. Comparamos dos candidatos:

- $\text{ARIMA}(3,1,0)$

$AIC = -204.04$

- $\text{ARIMA}(2,1,0)$

$AIC = -205.87$

Seleccionamos $\text{ARIMA}(2,1,0)$ porque:

- 1) Menor AIC
- 2) Todos los coeficientes son significativos ($t \approx 3.8$)
- 3) El tercer parámetro en $\text{ARIMA}(3,1,0)$ no era significativo

d. Diagnóstico del Modelo

Verificamos que nuestro modelo cumple los supuestos necesarios:

- Residuos con varianza constante (sin heterocedasticidad)
- Residuos aproximadamente normales (gráfico Q-Q)
- No autocorrelación residual (test de Ljung-Box)
- No se requieren componentes estacionales (datos anuales)

Figura 29: Análisis de Residuals





Figura 30: Resultados de los Residuals

Haciendo los ACFs de los residuos, vemos la diferencia entre el valor real y el que predice el modelo.

Como se puede observar, no hay ningún valor que se desvíe excesivamente (el que más destaca se ve cerca del 15 de los ACF of Residuals, pero incluso ese es aceptable).




iv. Resultados y Validación

Calculamos el incremento en puntos porcentuales (pp) de pobreza para cada grupo durante cada crisis, comparando el pico con el baseline de 3 años previos.

Tabla 14: Resultados

Grupo	Reagan (80-83)	DotCom (01-03)	Gran Recesión (08-10)	COVID-19 (20-21)
All	+3.63	+0.53	+2.63	+0.07
White	+3.23	-0.03	+1.67	+0.17
Black	+4.73	+0.33	+2.83	-0.67
Hispanic	+7.97	-0.77	+5.20	-0.10
Asian	NA	+0.77	+1.97	+0.17

Figura 31: Heatmap de incrementos por crisis



a. Recesión de Reagan (1980-1983)

- **Hispanos: +8.0 pp (de 21.9% a 29.9% en 1982)**
- Negros: +4.7 pp (de 31.0% a 35.7% en 1983)
- Total: +3.6 pp (de 11.6% a 15.2% en 1983)

b. Crisis DotCom (2001-2003)

- **Asiáticos: +0.8 pp (de 11.0% a 11.8% en 2003)**
- Total: +0.5 pp (de 12.0% a 12.5% en 2003)
- Negros: +0.3 pp (de 24.1% a 24.4% en 2003)

c. Gran Recesión (2008-2010)


- **Hispanos: +5.2 pp (de 21.3% a 26.5% en 2010)**
- Negros: +2.8 pp (de 24.6% a 27.4% en 2010)
- Total: +2.6 pp (de 12.5% a 15.1% en 2010)

d. COVID-19 (2020-2021)

- **Asiáticos: +0.2 pp (de 9.1% a 9.3% en 2021)**
- Blancos: +0.2 pp (de 8.0% a 8.2% en 2020)
- Total: +0.1 pp (de 11.5% a 11.6% en 2021)

v. Conclusiones

Figura 32: Incremento de pobreza por crisis



Hallazgos Principales:

1. Vulnerabilidad Diferencial Persistente

La población hispana emerge como el grupo más vulnerable en recesiones "tradicionales" (Reagan: +8.0 pp; Gran Recesión: +5.2 pp), mientras que la población asiática muestra mayor sensibilidad en crisis sectoriales/de salud pública.

2. La Política Fiscal Importa

Los incrementos en COVID-19 fueron dramáticamente menores que en crisis previas, sugiriendo que las intervenciones fiscales agresivas pueden mitigar efectivamente los impactos en la pobreza.

3. Heterogeneidad por Tipo de Crisis

No existe un "grupo más vulnerable" universal, la vulnerabilidad depende del tipo de shock económico.

Limitaciones Metodológicas:

- Armonización de categorías censales

Nuestra consolidación de categorías raciales (especialmente post-2002) implica simplificación.

- Método pico-vs-baseline

Captura magnitud pero no velocidad de recuperación ni persistencia a largo plazo.

Figura 33: Poverty Rate by Group

